

Le glossaire Data Analyst

40 termes, 1 exemple, 1 piège



Le vocabulaire SQL, Power BI et Python qui débloque la lecture d'une offre et l'entretien.

Un recruteur qui lit ton CV attend que tu comprennes son offre, pas que tu la récites. Ce glossaire ne liste pas des définitions de manuel : chaque terme vient avec l'exemple concret qui le rend réel, et le piège qui trahit un débutant, celui qui revient le plus souvent en entretien ou en premier poste.

Comment utiliser ce glossaire

Tu n'as pas besoin de tout lire d'une traite. Repère le palier qui correspond à l'offre que tu prépares, lis le terme, regarde l'exemple, retiens surtout le piège : c'est lui qui te fait repérer un niveau junior en entretien, dans un sens comme dans l'autre.

Palier 1 SQL	12 termes	Jointures, agrégats, fenêtres : est-ce que tes chiffres tiennent.
Palier 2 Power BI	10 termes	DAX, modèle en étoile, filtres : ce qui se passe derrière le visuel.
Palier 3 Python	10 termes	pandas, NumPy, vectorisation : lire du code sans le copier à l'aveugle.
Palier 4 Vocabulaire métier	8 termes	KPI, ETL, stakeholder : les mots qui rassurent un recruteur.

Observation terrain Datafuji : sur les derniers CV et cas pratiques de reconversion relus, la même faute technique revient sans arrêt, un **COUNT(*)** utilisé partout, y compris quand il fallait un **COUNT(DISTINCT ...)**. Ce glossaire part de ces erreurs vues en vrai, pas d'un manuel.

SQL : jointures, agrégats, fenêtres

Douze termes pour lire une requête et repérer où un chiffre peut se casser en silence.

1. JOIN PIÈGE CLASSIQUE

Définition : Un JOIN combine les lignes de deux tables selon une condition commune, en général une clé. L'INNER JOIN ne garde que les correspondances des deux côtés ; le LEFT JOIN garde toutes les lignes de gauche, même sans correspondance à droite.

```
SELECT c.nom, o.montant
FROM clients c
LEFT JOIN commandes o
  ON c.id = o.client_id;
```

Piège : Un junior confond souvent INNER et LEFT sans s'en rendre compte. S'il veut « tous les clients, même sans commande » mais écrit INNER JOIN, les clients sans commande disparaissent du résultat sans aucune erreur SQL. Le check à faire : compare le nombre de lignes avant et après le JOIN.

2. GROUP BY PIÈGE CLASSIQUE

Définition : GROUP BY regroupe les lignes qui partagent une valeur commune, pour appliquer une fonction d'agrégation (SUM, COUNT, AVG) sur chaque groupe.

```
SELECT region, SUM(montant) AS total
FROM ventes
GROUP BY region;
```

Piège : Toute colonne du SELECT qui n'est ni agrégée ni dans le GROUP BY plante ou renvoie une valeur arbitraire selon le moteur. Le réflexe : chaque colonne non agrégée doit être dans le GROUP BY, sinon le résultat n'a pas de sens garanti.

3. WHERE vs HAVING PIÈGE CLASSIQUE

Définition : WHERE filtre les lignes avant le regroupement; HAVING filtre les groupes après l'agrégation.

```
SELECT client_id, COUNT(*) AS nb
FROM commandes
WHERE statut = 'payee'
GROUP BY client_id
HAVING COUNT(*) > 5;
```

Piège : Écrire un filtre sur une valeur agrégée directement dans le WHERE fait planter la requête, car l'agrégat n'existe pas encore à ce stade. Un filtre sur une valeur agrégée va toujours dans HAVING, jamais dans WHERE.

4. Clé primaire PIÈGE CLASSIQUE

Définition : La clé primaire est la colonne, ou combinaison de colonnes, qui identifie une ligne de façon unique et jamais NULL dans une table.

Exemple : Dans une table clients, id_client est la clé primaire : deux lignes ne peuvent jamais avoir le même id_client, et il ne peut pas être vide.

Piège : Un junior confond clé primaire et clé unique. Une clé primaire est unique par définition, mais une table peut aussi avoir des colonnes uniques (un email) sans qu'elles soient la clé primaire. Vérifie toujours la clé primaire d'une table avant de joindre dessus, pour éviter des doublons inattendus.

À retenir : les pièges SQL qui reviennent en entretien

Un chiffre peut être faux sans qu'aucune requête ne plante.

JOIN

Vérifier les doublons avant de joindre.

WHERE / HAVING

Filtre agrégé toujours dans HAVING.

GROUP BY

Aucune colonne hors agrégat ou hors GROUP BY.

Clé primaire

Unique n'est pas toujours primaire.

5. Clé étrangère PIÈGE CLASSIQUE

Définition : Une clé étrangère est une colonne qui référence la clé primaire d'une autre table, pour garantir que la relation entre les deux existe réellement.

```
-- commandes.client_id référence clients.id
ALTER TABLE commandes
  ADD FOREIGN KEY (client_id)
  REFERENCES clients(id);
```

Piège : Sans contrainte active, rien n'empêche une commande de pointer vers un client_id qui n'existe plus. Le JOIN exclut ou garde en NULL cette ligne selon le type de jointure, ce qui fausse les totaux sans erreur visible.

6. Sous-requête PIÈGE CLASSIQUE

Définition : Une sous-requête est une requête SQL imbriquée à l'intérieur d'une autre, utilisée dans le SELECT, le WHERE ou le FROM.

```
SELECT nom FROM clients
WHERE id IN (
  SELECT client_id FROM commandes
  WHERE montant > 1000
);
```

Piège : Une sous-requête corrélée, réexécutée pour chaque ligne externe, peut devenir très lente sur un gros volume. Si la même sous-requête revient plusieurs fois, la remplacer par une CTE la rend plus lisible et souvent plus rapide.

7. CTE, le WITH PIÈGE CLASSIQUE

Définition : Une CTE (Common Table Expression), introduite par WITH, nomme un résultat intermédiaire réutilisable dans la requête qui suit.

```
WITH ventes_region AS (
  SELECT region, SUM(montant) AS total
  FROM ventes GROUP BY region
)
SELECT * FROM ventes_region
WHERE total > 50000;
```

Piège : Beaucoup de juniors pensent qu'une CTE est automatiquement plus rapide qu'une sous-requête imbriquée. Ce n'est pas garanti, ça dépend du moteur. Le vrai gain d'une CTE, c'est la lisibilité et la réutilisation, pas la performance par défaut.

8. Window function PIÈGE CLASSIQUE

Définition : Une fonction de fenêtrage calcule une valeur sur un ensemble de lignes liées à la ligne courante, via PARTITION BY, sans réduire le nombre de lignes affichées, contrairement à GROUP BY.

```
SELECT client_id, montant,
  RANK() OVER (
    PARTITION BY client_id
    ORDER BY montant DESC
  ) AS rang
FROM commandes;
```

Piège : Confondre window function et GROUP BY est un classique. GROUP BY réduit à une ligne par groupe; la window function garde toutes les lignes de détail en ajoutant une colonne calculée. Utiliser GROUP BY quand on veut garder le détail fait perdre l'information.

GROUP BY vs Window function, en une ligne

GROUP BY

Réduit à une ligne par groupe.

Window function

Garde toutes les lignes, ajoute une colonne calculée.

9. Index PIÈGE CLASSIQUE

Définition : Un index est une structure qui accélère la recherche sur une colonne, un peu comme le sommaire d'un livre, au prix d'un coût d'écriture et de stockage supplémentaire.

Exemple : Indexer `client_id` dans une table de 5 millions de commandes rend les JOIN et les filtres sur cette colonne beaucoup plus rapides.

Piège : Un junior a tendance à indexer trop de colonnes « au cas où ». Chaque index ralentit les INSERT/UPDATE et prend de la place. La règle : indexer les colonnes utilisées dans les JOIN, WHERE et ORDER BY fréquents, pas toutes les colonnes.

10. NULL PIÈGE CLASSIQUE

Définition : NULL représente une valeur absente ou inconnue. Il n'est égal à rien, pas même à un autre NULL.

```
SELECT * FROM clients
WHERE email IS NULL;    -- pas "=" NULL"
```

Piège : Écrire `WHERE colonne = NULL` ne renvoie jamais de résultat, car NULL n'est comparable qu'avec `IS NULL` ou `IS NOT NULL`. C'est une erreur silencieuse : la requête tourne sans planter mais renvoie un mauvais résultat.

11. Fonction d'agrégation PIÈGE CLASSIQUE

Définition : Une fonction d'agrégation, COUNT, SUM, AVG, MIN ou MAX, réduit un ensemble de lignes à une seule valeur.

```
SELECT COUNT(*) AS total_lignes,
       COUNT(email) AS avec_email,
       COUNT(DISTINCT client_id) AS clients_uniques
FROM commandes;
```

Piège : COUNT(*) compte toutes les lignes, NULL compris; COUNT(colonne) ignore les NULL de cette colonne. Un junior qui utilise COUNT(*) pour « combien de clients ont un email » surestime le chiffre sans le savoir.

12. Normalisation PIÈGE CLASSIQUE

Définition : La normalisation organise les données pour éviter la redondance, en séparant l'information en plusieurs tables reliées par des clés.

Exemple : Séparer les tables `clients` et `commandes` plutôt que répéter le nom du client sur chaque ligne de commande.

Piège : En reporting, une normalisation trop poussée oblige à multiplier les JOIN pour un simple graphique, ce qui ralentit tout. Pour l'analyse, on dénormalise volontairement, comme dans un modèle en étoile : c'est un choix, pas un oubli.

Power BI : DAX, modèle, filtres

Dix termes pour comprendre ce qui se passe derrière un visuel, pas juste cliquer dessus.

13. DAX PIÈGE CLASSIQUE

Définition : DAX, pour Data Analysis Expressions, est le langage de formules utilisé pour créer des mesures et des colonnes calculées dans Power BI.

```
Total Ventes = SUM(Ventes[Montant])
```

Piège : Un junior confond souvent DAX (calcul) et Power Query (transformation). DAX s'exécute quand le visuel s'affiche ; Power Query transforme les données avant qu'elles entrent dans le modèle. Faire en DAX une transformation qui aurait dû se faire en Power Query alourdit le modèle.

14. Mesure vs colonne calculée PIÈGE CLASSIQUE

Définition : Une colonne calculée est évaluée ligne par ligne à l'actualisation puis stockée dans le modèle ; une mesure est calculée à la volée selon le contexte du visuel et n'est jamais stockée.

```
Marge% (colonne) = DIVIDE(Ventes[Marge], Ventes[CA])  
Marge% (mesure) = DIVIDE(SUM(Ventes[Marge]), SUM(Ventes[CA]))
```

Piège : Un classique junior : créer une colonne calculée pour un KPI qui doit réagir aux filtres du dashboard. Le chiffre reste figé quel que soit le filtre appliqué, car il a été calculé une fois pour toutes à l'actualisation.

15. Power Query PIÈGE CLASSIQUE

Définition : Power Query est l'éditeur qui nettoie et transforme les données, filtrer, renommer, fusionner des colonnes, avant qu'elles n'entrent dans le modèle Power BI.

Exemple : Renommer une colonne, supprimer les doublons ou fusionner deux tables sources se fait dans Power Query, pas en DAX.

Piège : Faire en DAX une transformation qui devrait être faite en amont alourdit le modèle et complique la maintenance. La règle simple : transformer les données en Power Query, calculer des indicateurs en DAX.

16. Modèle en étoile PIÈGE CLASSIQUE

Définition : Le modèle en étoile place une table de faits, les mesures, au centre, reliée à des tables de dimension (client, produit, date) autour, chacune reliée une seule fois.

Exemple : Une table Ventes reliée à Clients, Produits et Calendrier, sans relation directe entre Clients et Produits.

Piège : Un modèle en toile d'araignée, où les tables sont reliées entre elles dans tous les sens, rend les filtres imprévisibles et les mesures DAX difficiles à déboguer. Toujours viser une étoile simple avant d'ajouter des relations complexes.

À retenir : DAX et modélisation, les erreurs qui coûtent cher

Le recruteur veut savoir si tu comprends l'effet sur le modèle, pas juste la définition.

Colonne calculée

Figée à l'actualisation, ne réagit pas aux filtres.

Mesure

Recalculée en direct selon le visuel.

Étoile

Lisible, prévisible pour DAX.

Toile d'araignée

Filtres imprévisibles, mesures dures à déboguer.

17. Relation, la cardinalité PIÈGE CLASSIQUE

Définition : La cardinalité d'une relation décrit le rapport entre les lignes des deux tables reliées : un-à-plusieurs, le cas standard, un-à-un ou plusieurs-à-plusieurs.

Exemple : Une relation un-à-plusieurs entre Clients (un) et Ventes (plusieurs) : un client a plusieurs ventes.

Piège : Activer une relation bidirectionnelle « pour que ça marche dans les deux sens » sans en comprendre l'effet peut créer des filtres croisés inattendus et des totaux qui changent selon le visuel. À réserver aux cas où le besoin est identifié.

18. Filtre de contexte PIÈGE CLASSIQUE

Définition : Le contexte de filtre est l'ensemble des filtres actifs au moment où une mesure est évaluée : ceux des visuels, des segments et des relations du modèle.

```
Ventes Filtrees =  
CALCULATE(  
    SUM(Ventes[Montant]),  
    Ventes[Categorie] = "Promo"  
)
```

Piège : Un junior utilise CALCULATE sans réaliser qu'il remplace le contexte de filtre existant, pas qu'il l'ajoute forcément. Un filtre déjà posé sur la même colonne est remplacé, pas cumulé, et le résultat peut ignorer un filtre du visuel sans que ça se voie.

19. Slicer PIÈGE CLASSIQUE

Définition : Un slicer, ou segment, est un visuel de filtre interactif que l'utilisateur manipule directement sur le rapport.

Exemple : Un slicer sur l'année laisse l'utilisateur basculer entre 2023 et 2024 sans toucher au code du rapport.

Piège : Par défaut, un slicer ne filtre que la page où il se trouve. Un junior qui veut un filtre global oublie de le synchroniser sur les autres pages, et les visuels ailleurs restent non filtrés sans erreur visible.

20. Bookmark PIÈGE CLASSIQUE

Définition : Un bookmark, ou signet, enregistre l'état d'un rapport, filtres, visuels visibles, zoom, pour le rejouer d'un clic, souvent pour créer une navigation ou une bascule de vue.

Exemple : Un bookmark « Vue résumé » et un bookmark « Vue détail », reliés à deux boutons, permettent de basculer sans changer de page.

Piège : Utiliser les bookmarks uniquement pour un effet visuel, sans qu'ils servent une navigation ou une comparaison utile, ajoute de la complexité de maintenance sans valeur pour le lecteur du rapport.

Un rapport Power BI est lent, où regarder en premier

Colonnes calculées

En trop, à remplacer par des mesures.

Relations bidirectionnelles

Actives sans besoin identifié.

Visuels par page

Trop de visuels qui interrogent le modèle en même temps.

21. Row-Level Security, la RLS PIÈGE CLASSIQUE

Définition : La RLS restreint les lignes visibles selon l'identité de l'utilisateur connecté, par exemple un manager régional qui ne voit que sa région.

Exemple : Une règle RLS filtre la table Ventes sur la région de l'utilisateur connecté, pour que chaque manager ne voie que ses propres chiffres.

Piège : Un junior configure la RLS puis teste uniquement avec son propre compte administrateur, qui voit tout par défaut. Il faut utiliser « Afficher en tant que » pour chaque rôle avant de publier, sinon une fuite de données passe inaperçue.

22. Actualisation des données PIÈGE CLASSIQUE

Définition : L'actualisation recharge les données du modèle depuis la source; elle peut être manuelle, à la demande, ou planifiée, automatique à heure fixe.

Exemple : Une actualisation planifiée chaque nuit à 5h garde le dashboard à jour sans intervention.

Piège : Un rapport figé, qui a raison hier mais pas aujourd'hui, trahit souvent une actualisation manuelle oubliée plutôt qu'une planifiée. Avant de commenter un chiffre bizarre, vérifie la date de dernière actualisation.

Python : pandas, NumPy, vectorisation

Dix termes pour lire du code sans le copier à l'aveugle.

23. DataFrame PIÈGE CLASSIQUE

Définition : Un DataFrame est une table à deux dimensions, lignes et colonnes, fournie par pandas, l'équivalent Python d'une feuille Excel ou d'une table SQL.

```
import pandas as pd
df = pd.read_csv("ventes.csv")
df.head()
```

Piège : `df2 = df` ne crée pas une copie, mais une référence : modifier `df2` modifie `df`. Le réflexe à avoir, utiliser `df.copy()` dès qu'on veut travailler sur une version indépendante.

24. pandas PIÈGE CLASSIQUE

Définition : pandas est la bibliothèque Python de référence pour charger, nettoyer et analyser des données tabulaires.

Exemple : Charger un CSV, filtrer les lignes, calculer une moyenne par groupe : trois opérations pandas courantes en une dizaine de lignes.

Piège : Utiliser pandas comme une boîte noire, en copiant du code trouvé en ligne sans comprendre l'index ou les types de colonnes, mène à des erreurs silencieuses. Toujours vérifier `df.dtypes` et `df.info()` avant d'analyser.

25. groupby, en Python PIÈGE CLASSIQUE

Définition : La méthode `.groupby()` regroupe les lignes d'un DataFrame par valeur commune pour appliquer un calcul par groupe, l'équivalent du GROUP BY SQL.

```
df.groupby("region")["montant"].sum()
```

Piège : Confondre `.agg()`, une fonction résumée par groupe, et `.apply()`, une fonction libre appliquée à chaque groupe, plus lente et parfois imprévisible en type de retour. Utiliser `apply` par réflexe quand `agg` suffit ralentit le calcul sans raison.

26. merge, ou join PIÈGE CLASSIQUE

Définition : La méthode `.merge()` combine deux DataFrames selon une ou plusieurs colonnes communes, comme un JOIN SQL.

```
pd.merge(clients, commandes,  
         on="client_id", how="left")
```

Piège : Le paramètre `how` par défaut est `"inner"`, pas `"left"`. Un junior qui ne le précise pas perd silencieusement les lignes sans correspondance, exactement comme un mauvais JOIN SQL. Toujours écrire `how=` explicitement.

À retenir : les pièges pandas les plus fréquents

Le code tourne sans erreur, mais le résultat n'est plus le bon.

Copie

`df.copy()`, jamais `df2 = df`.

merge

Toujours préciser `how=`.

27. NaN PIÈGE CLASSIQUE

Définition : NaN, Not a Number, est la valeur pandas pour une donnée manquante ou non numérique dans une colonne.

```
df["montant"].isna().sum()
```

Piège : `NaN == NaN` renvoie `False` en Python : on ne peut pas filtrer les valeurs manquantes avec une comparaison classique. Il faut utiliser `.isna()` ou `.notna()`, jamais `== NaN`.

28. List comprehension PIÈGE CLASSIQUE

Définition : Une list comprehension construit une liste en une ligne à partir d'une boucle et d'une condition, de façon plus concise qu'une boucle `for` classique.

```
pairs = [x for x in nombres if x % 2 == 0]
```


Piège : Empiler plusieurs boucles et conditions dans une seule list comprehension la rend illisible pour quelqu'un qui reprend le code. Passé une ou deux conditions, une boucle for classique documentée reste préférable à la concision à tout prix.

29. Environnement virtuel PIÈGE CLASSIQUE

Définition : Un environnement virtuel isole les bibliothèques Python installées pour un projet, pour éviter les conflits de version entre projets.

```
python -m venv .venv
source .venv/bin/activate
pip install -r requirements.txt
```

Piège : Installer les bibliothèques directement dans l'environnement Python global, pour aller plus vite, casse tôt ou tard un autre projet qui a besoin d'une version différente de la même bibliothèque, souvent au pire moment.

30. Jupyter Notebook PIÈGE CLASSIQUE

Définition : Un Jupyter Notebook exécute du code Python par cellules indépendantes, avec le résultat affiché directement sous chaque cellule.

Exemple : Une cellule charge les données, une autre les nettoie, une troisième trace un graphique : on peut relancer une seule cellule sans tout réexécuter.

Piège : L'ordre affiché n'est pas forcément l'ordre réel d'exécution : si tu exécutes la cellule 3 puis reviens modifier la cellule 1, la mémoire ne reflète plus le fichier lu de haut en bas. Avant de partager un notebook, relance tout (Restart & Run All).

Boucle vs vectorisation, en une ligne

Boucle for

Lente, une itération Python par ligne.

Vectorisation

Rapide, calcul appliqué à toute la colonne d'un coup.

31. NumPy PIÈGE CLASSIQUE

Définition : NumPy est la bibliothèque de calcul numérique sur laquelle pandas est construit; elle fournit le type array, optimisé pour les calculs sur de grands volumes.

```
import numpy as np
arr = np.array([1, 2, 3])
arr * 2    # -> [2, 4, 6]
```

Piège : Un array NumPy n'est pas une liste Python : multiplier une liste par 2 la duplique, multiplier un array la multiplie terme à terme. Confondre les deux donne un résultat totalement différent sans erreur.

32. Vectorisation PIÈGE CLASSIQUE

Définition : La vectorisation applique une opération à toute une colonne ou un tableau d'un coup, sans boucle explicite, en s'appuyant sur NumPy et pandas.

```
df["ttc"] = df["ht"] * 1.2 # vectorise
```

Piège : Écrire une boucle for qui parcourt chaque ligne d'un DataFrame pour un calcul simple est beaucoup plus lent que la version vectorisée, et c'est un signal reconnu de niveau junior en entretien technique.

Vocabulaire métier transverse

Huit mots que tout recruteur attend, quel que soit l'outil du poste.

33. KPI PIÈGE CLASSIQUE

Définition : Un KPI, Key Performance Indicator, est un indicateur choisi parce qu'il est directement lié à un objectif métier et qu'il peut déclencher une action.

Exemple : Le taux de conversion est un KPI pour une équipe e-commerce, car une baisse déclenche une investigation et une action.

Piège : Un « KPI de vanité » (nombre de vues, de likes) fait bien sur un dashboard mais ne relie à aucune décision. Avant de proposer un indicateur, demande-toi : si ce chiffre baisse de 10%, qui fait quoi de différent ?

34. Dashboard PIÈGE CLASSIQUE

Définition : Un dashboard rassemble plusieurs indicateurs sur une même vue pour permettre un suivi rapide d'une activité.

Exemple : Un dashboard commercial affiche le CA du mois, le taux de conversion et le panier moyen, avec leur évolution.

Piège : Construire un dashboard « parce qu'on nous l'a demandé », sans connaître la question métier qu'il doit servir, produit un objet qu'on regarde une fois puis qu'on ignore. Demande toujours quelle décision il doit permettre de prendre.

35. ETL PIÈGE CLASSIQUE

Définition : ETL, pour Extract, Transform, Load, désigne le processus qui extrait des données d'une source, les transforme, puis les charge dans une destination, entrepôt ou base analytique.

Exemple : Extraire les commandes d'une base transactionnelle, nettoyer les doublons, charger le résultat dans l'entrepôt utilisé pour le reporting.

Piège : Confondre ETL et ELT : dans l'ELT, les données brutes sont chargées d'abord, transformées ensuite dans l'entrepôt, approche courante avec les outils cloud. Employer les deux termes indifféremment signale un vocabulaire mal maîtrisé.

36. Source de vérité unique PIÈGE CLASSIQUE

Définition : La source de vérité unique, single source of truth, est la référence commune où tout le monde va chercher le même chiffre, pour éviter que chaque équipe calcule sa propre version.

Exemple : Le CA du mois est calculé une seule fois dans l'entrepôt de données, puis lu par toutes les équipes, plutôt que recalculé dans chaque tableau.

Piège : Sans source de vérité unique, deux équipes présentent en réunion deux chiffres différents pour la même métrique. Le vrai problème est presque toujours une définition différente, périmètre ou période, pas une erreur de calcul.

À retenir : le vocabulaire qui rassure un recruteur

Ces quatre mots montrent que tu relies un terme à une décision, pas juste à une définition.

KPI

Relié à une décision, pas à un chiffre qui fait joli.

Dashboard

Répond à une question métier précise.

ETL

À ne pas confondre avec l'ELT.

Source de vérité unique

Un chiffre, une définition, partagés.

37. Outlier PIÈGE CLASSIQUE

Définition : Un outlier, valeur aberrante, est une valeur très éloignée de la distribution du reste des données, qui peut être une erreur ou une donnée réelle exceptionnelle.

Exemple : Une commande à 500 000 euros dans une base où le panier moyen est de 80 euros est un outlier : erreur de saisie ou vraie grosse commande, à vérifier avant de trancher.

Piège : Supprimer automatiquement les outliers sans les regarder fausse parfois l'analyse plus que de les garder, car certains sont l'information la plus importante, une fraude, un client majeur. Toujours investiguer avant de décider.

38. Data cleaning PIÈGE CLASSIQUE

Définition : Le data cleaning, nettoyage de données, corrige ou retire les valeurs manquantes, dupliquées ou incohérentes avant l'analyse.

Exemple : Uniformiser « France », « FR » et « france » en une seule valeur avant de compter les ventes par pays.

Piège : Nettoyer des données sans documenter les règles appliquées, colonnes touchées, lignes supprimées, valeurs remplacées, rend le travail impossible à vérifier ou reproduire. Un script ou une note doit toujours accompagner le résultat.

39. Stakeholder PIÈGE CLASSIQUE

Définition : Un stakeholder, partie prenante, est une personne ou une équipe concernée par le résultat d'une analyse, qui en a besoin pour décider ou agir.

Exemple : Pour une analyse de churn, le stakeholder peut être le responsable rétention qui doit décider d'un budget de relance.

Piège : Livrer une analyse « techniquement juste » sans avoir reformulé le besoin du stakeholder en amont produit souvent un résultat qui répond à la mauvaise question. Reformuler la demande avant de commencer évite de refaire le travail.

40. A/B test PIÈGE CLASSIQUE

Définition : Un A/B test compare deux versions, A et B, d'un même élément auprès de deux groupes d'utilisateurs similaires, pour mesurer laquelle performe mieux.

Exemple : Tester deux versions d'un bouton d'achat, la moitié des visiteurs voit A, l'autre voit B, on compare le taux de clic.

Piège : Conclure « B est meilleur » après un petit échantillon ou sans test de signification statistique peut confondre un effet réel avec du hasard. Avant d'annoncer un gagnant, vérifie la taille d'échantillon et la significativité.

À retenir : les pièges qui reviennent le plus souvent en entretien

40 termes, 40 pièges : une référence à garder sous la main avant l'entretien.

SQL

Un JOIN ou un GROUP BY mal posé fausse un chiffre sans erreur visible.

Power BI

Une colonne calculée à la place d'une mesure fige un KPI.

Python

how= oublié dans un merge, comme un mauvais JOIN.

Tu n'as pas besoin de réciter ces 40 définitions au mot près. Tu dois surtout retenir la posture : nommer le piège avant qu'on te le demande. C'est ça qui fait la différence entre quelqu'un qui a lu une offre et quelqu'un à qui on peut confier une analyse.

Fait main, en solo.

Si ce glossaire t'a aidé à préparer un entretien, partage-le autour de toi : il peut débloquent un autre candidat en reconversion. Et si un terme te manque ou te bloque encore, dis-le moi en commentaire : c'est là que je pioche mes prochains guides.

Dylan

