

20 questions Stats

Test technique /20



Le test blanc que tu n'as pas eu à l'entretien. Durée conseillée : 20 min · 3 paliers · corrigé détaillé.

J'ai recroisé les questions stats qui reviennent le plus dans les entretiens juniors que j'accompagne : outliers, pourcentages, biais d'échantillon. Ce test vérifie si tu sais lire un chiffre avant de le présenter, pas si tu connais une formule par cœur.

Repères : 12/20 = junior, 17/20 = profil qu'on garde.

Candidat _____ Date _____ Note _____ /20

Palier 1 : lire un chiffre avant de le présenter.

Neuf questions sur les bases descriptives : distribution, outliers, mesure centrale. Le socle que le recruteur teste en premier.

Question 1. Reporting salaires équipe : un poste de direction fait exploser la moyenne. Quel indicateur choisir pour décrire le salaire « typique » de l'équipe ?

- a) La médiane, car un salaire extrême ne la fait pas bouger.
- b) La moyenne, car elle utilise tous les salaires disponibles.
- c) Le mode, car c'est la valeur la plus fréquente.
- d) L'écart-type, car il résume la dispersion.

Question 2. Les temps de traitement des tickets support sont rapides pour la plupart, avec une longue traîne de tickets très lents (asymétrie à droite). Que peux-tu dire de la moyenne face à la médiane ?

- a) Moyenne = médiane, l'asymétrie n'a pas d'effet.
- b) Moyenne < médiane, tirée vers le bas par les tickets rapides.
- c) Moyenne > médiane, tirée vers le haut par la longue traîne de tickets lents.
- d) Impossible à dire sans connaître l'écart-type.

Question 3. Ta colonne « canal d'acquisition » contient des catégories (SEO, Ads, Referral...). Quelle mesure de tendance centrale a du sens ici ?

- a) La moyenne des catégories encodées en chiffres.
- b) La médiane des catégories.
- c) Le mode, la catégorie la plus fréquente.
- d) L'écart-type des catégories.

Question 4. L'histogramme des montants de commande affiche deux pics distincts. Quelle est la lecture la plus probable ?

- a) Une erreur de calcul, un histogramme ne peut avoir qu'un seul pic.
- b) Le signe probable de deux sous-populations mélangées (ex : particuliers et entreprises).
- c) Un signe que la moyenne est la meilleure mesure à utiliser ici.
- d) Un artefact sans conséquence sur l'analyse.

Question 5. Sur un boxplot, la ligne de médiane n'est pas centrée dans la boîte : elle est proche du bord inférieur. Que faut-il en conclure ?

- a) Une erreur d'affichage du logiciel.
- b) Une distribution symétrique.
- c) Un échantillon trop petit pour être valide.
- d) Une distribution asymétrique : une moitié des données est plus dispersée que l'autre.

Question 6. La distribution des ventes selon le jour du mois est quasi plate (uniforme). Quelle est la bonne lecture ?

- a) Il n'y a pas de valeur « typique » à retenir : toutes les valeurs sont à peu près également probables.
- b) La moyenne représente parfaitement le comportement observé.
- c) C'est un signe d'erreur dans la collecte de données.
- d) Le mode est la meilleure mesure ici.

Question 7. Quelle est la convention usuelle pour repérer un outlier à partir de l'écart interquartile ?

- a) Une valeur au-delà de 3 écarts-types de la moyenne.
- b) Une valeur en dehors de $[Q1 - 1,5 \times IQR; Q3 + 1,5 \times IQR]$, la convention de Tukey.
- c) Toute valeur supérieure à la médiane +50%.
- d) Une valeur qui dépasse le maximum observé l'année précédente.

Question 8. Tu repères une valeur extrême dans un rapport avant de l'envoyer au client. Quel est le bon réflexe ?

- a) La supprimer immédiatement pour ne pas fausser la moyenne.
- b) La remplacer par la médiane sans vérifier.
- c) L'ignorer, un seul point ne change rien.
- d) Vérifier son origine (erreur de saisie, cas réel) avant toute décision.

Question 9. Un seul outlier isolé apparaît dans ton jeu de données. Quelles mesures sont les plus affectées ?

- a) La médiane est la plus sensible aux valeurs extrêmes.
- b) Le mode est le plus sensible.
- c) La moyenne et l'écart-type sont les plus sensibles, la médiane résiste mieux.
- d) Aucune de ces mesures n'est affectée par un outlier isolé.

Palier 2 : le piège du pourcentage.

Sept questions où le chiffre est juste, mais la phrase qui l'accompagne est fausse. C'est le palier où je vois le plus d'erreurs en entretien.

Question 10. Un rapport annonce : « le taux de conversion est passé de 10% à 15%, soit +5% ». Que corriger dans cette phrase ?

- a) La phrase est correcte telle quelle, +5% est la bonne façon de le dire.
- b) Il faut préciser : +5 points de pourcentage (valeur absolue) ou +50% en relatif, ce n'est pas la même chose.
- c) Le taux a en réalité doublé, donc +100%.
- d) La différence entre points et pourcentage relatif n'a pas d'importance en reporting.

Question 11. Le service marketing annonce fièrement : « nos ventes ont doublé ce mois-ci ! », en passant de 2 à 4 ventes. Quelle est la lecture correcte ?

- a) La base est trop petite pour que « doubler » soit un signal fiable : 2 à 4 reste anecdotique.
- b) L'affirmation est solide, un doublement reste un doublement.
- c) Il faudrait plutôt dire que les ventes ont été multipliées par 4.
- d) Ce chiffre prouve une tendance de fond sur le trimestre.

Question 12. Le churn mensuel est de 5%. Un collègue en déduit un churn annuel de 60% ($5\% \times 12$). Quel est le churn annuel réellement attendu ?

- a) 60%, en multipliant 5% par 12 mois.
- b) 5%, le taux mensuel reste valable sur l'année.
- c) Impossible à estimer sans données mensuelles détaillées.
- d) Environ 46%, calculé avec un taux composé : $1 - (0,95)^{12}$.

Question 13. Le prix d'un produit baisse de 50%, puis remonte de 50%. Un collègue dit : « on est revenu au prix de départ ». A-t-il raison ?

- a) Il a raison, les deux pourcentages s'annulent.
- b) Faux, le prix final est plus élevé que le prix de départ.
- c) Faux : -50% puis +50% ramène seulement à 75% du prix initial, car les deux pourcentages s'appliquent à des bases différentes.
- d) La réponse dépend du produit concerné.

Question 14. Les ventes de glaces et le nombre de noyades augmentent ensemble chaque été. Comment expliquer cette corrélation ?

- a) La consommation de glaces provoque les noyades.
- b) La chaleur explique les deux : c'est une variable confondante.
- c) Les noyades provoquent la consommation de glaces.
- d) Il n'existe aucun lien, même statistique, entre les deux séries.

Question 15. Un rapport affirme : « le trafic web et les ventes sont corrélés, donc le trafic cause les ventes ». Que penser de cette conclusion ?

- a) La corrélation ne dit rien sur le sens de la causalité, ni même si elle existe réellement.
- b) La conclusion est correcte, la corrélation suffit à établir la causalité.
- c) C'est plutôt les ventes qui causent le trafic, jamais l'inverse.
- d) Une corrélation forte (proche de 1) devient automatiquement causale.

Question 16. Le coefficient de corrélation de Pearson entre deux variables est proche de 0. Un collègue conclut : « il n'y a aucun lien entre elles ». Que répondre ?

- a) Conclusion correcte : une corrélation nulle signifie une absence totale de lien.
- b) La corrélation nulle prouve une relation causale inverse.
- c) Il faut simplement recalculer avec plus de décimales.
- d) Conclusion risquée : une corrélation de Pearson proche de 0 n'exclut pas une relation non linéaire (ex : en U).

Palier 3 : biais et significativité.

Quatre questions sur les échantillons trompeurs et les p-values mal lues. Le terrain classique du dernier tour d'entretien.

Question 17. Un sondage de satisfaction est envoyé uniquement aux clients ayant accepté de recevoir des emails, et affiche 95% de satisfaits. Quel est le problème ?

- a) Le résultat est fiable, l'échantillon est assez grand.
- b) Le taux de satisfaction serait identique sur l'ensemble des clients.
- c) C'est un biais de sélection : seuls les clients ayant accepté les emails ont pu répondre.
- d) C'est un biais du survivant.

Question 18. « J'ai étudié 20 startups à succès, elles ont toutes levé des fonds très vite : donc lever vite garantit le succès. » Quel est le défaut de ce raisonnement ?

- a) C'est un biais du survivant : l'échantillon ignore les startups qui ont levé vite et échoué.
- b) Le raisonnement est solide, l'échantillon est pertinent.
- c) C'est un biais de sélection lié aux emails.
- d) C'est une variable confondante classique.

Question 19. Pour se faire une idée des utilisateurs d'un produit, un analyste interroge 10 collègues de bureau. Que penser de cet échantillon ?

- a) Représentatif, car ce sont de vrais utilisateurs.
- b) Suffisant statistiquement à partir de 10 personnes.
- c) Plus fiable qu'un sondage aléatoire.
- d) Un échantillon de convenance, pratique mais non représentatif de la population totale.

Question 20. Un test A/B renvoie une p-value de 0,01. Un collègue en conclut : « l'effet est énorme ». Que répondre ?

- a) Une p-value faible prouve que l'effet observé est important en pratique.
- b) Une p-value faible signifie seulement que le résultat est peu probable si l'hypothèse nulle est vraie; elle ne dit rien sur la taille de l'effet.
- c) La p-value mesure la probabilité que l'hypothèse nulle soit vraie.
- d) La p-value et la taille d'effet sont toujours proportionnelles.

Solutions et explications.

Un point par bonne réponse. Compte ton score, puis relis surtout celles que tu ne peux pas expliquer à voix haute.

1. **a)** La médiane ignore la position exacte des valeurs extrêmes; le piège classique est de garder la moyenne par réflexe alors qu'un seul salaire haut la fait grimper.
2. **c)** Une longue traîne à droite tire la moyenne au-dessus de la médiane; croire qu'elles restent égales masque la vraie durée typique de traitement.
3. **c)** Une variable catégorielle n'a pas d'ordre numérique : moyenne et écart-type n'ont pas de sens, seul le mode (la catégorie la plus fréquente) est interprétable.
4. **b)** Deux pics signalent presque toujours deux populations mélangées; calculer une moyenne globale sur ce mélange donne un chiffre qui ne décrit aucun des deux groupes.
5. **d)** Une médiane décentrée dans la boîte trahit une asymétrie : une moitié des valeurs est plus étalée que l'autre, ce n'est pas un bug d'affichage.
6. **a)** Dans une distribution uniforme, aucune valeur n'est plus probable qu'une autre : parler d'un jour "typique" ou utiliser un mode n'a pas de sens ici.
7. **b)** La convention de Tukey fixe le seuil à $Q1 - 1,5 \times IQR$ et $Q3 + 1,5 \times IQR$; le piège est de confondre ce seuil avec la règle des 3 écarts-types, qui suppose une distribution normale.
8. **d)** Avant de supprimer ou remplacer une valeur extrême, il faut vérifier son origine : une erreur de saisie se corrige, un cas réel (gros client, événement rare) doit rester dans l'analyse.
9. **c)** Moyenne et écart-type intègrent chaque valeur dans leur calcul, donc un outlier les déplace fortement; la médiane, qui ne regarde que le rang central, résiste bien mieux.
10. **b)** 10% à 15% fait +5 points de pourcentage en valeur absolue, mais +50% en évolution relative (5/10); le piège est de mélanger les deux formulations dans un même rapport.
11. **a)** Passer de 2 à 4 ventes est un doublement arithmétique, mais la base est trop petite pour en tirer une tendance : le même langage ("doublé") s'utiliserait pour 2 000 à 4 000 ventes, un signal bien plus solide.
12. **d)** Un taux composé ne s'additionne pas : le churn annuel se calcule par $1 - (1 - 0,05)^{12}$, soit environ 46%, loin des 60% obtenus en multipliant naïvement 5% par 12.
13. **c)** -50% s'applique au prix initial, +50% s'applique ensuite au prix déjà réduit : les deux pourcentages portent sur des bases différentes, le résultat final reste à 75% du prix de départ.
14. **b)** La chaleur estivale pousse à la fois la vente de glaces et les baignades (donc les noyades) : c'est une variable confondante, ni l'une ni l'autre série ne cause directement l'autre.
15. **a)** Une corrélation, même forte, ne dit rien sur qui cause quoi ni si un facteur externe explique les deux; conclure à la causalité à partir d'une seule corrélation est le piège le plus fréquent en reporting.
16. **d)** Pearson ne mesure que les relations linéaires; une relation en U ou en cloche peut donner un coefficient proche de 0 tout en étant un lien réel et exploitable.
17. **c)** Ne répondent que les clients ayant accepté les emails, un groupe déjà plus engagé : c'est un biais de sélection, le taux ne représente pas l'ensemble de la clientèle.
18. **a)** Étudier uniquement les startups qui ont réussi occulte celles qui ont levé vite et échoué : c'est le biais du survivant, il fausse toute conclusion sur "ce qui marche".
19. **d)** Interroger ses collègues de bureau est un échantillon de convenance : facile à obtenir, mais rien ne garantit qu'il ressemble à la population réelle des utilisateurs.
20. **b)** La p-value indique seulement la probabilité d'observer un résultat au moins aussi extrême si l'hypothèse nulle est vraie; elle ne mesure ni la taille de l'effet ni la probabilité que H_0 soit vraie, le piège classique en entretien.

5 réflexes stats à retenir avant l'entretien :

1. Face à un outlier, vérifie son origine avant de le supprimer ou de le garder.
2. Distingue toujours points de pourcentage et pourcentage relatif dans une phrase.
3. Un taux mensuel ne se multiplie pas par 12 : compose-le.
4. Une corrélation ne prouve ni le sens ni l'existence d'une causalité.
5. Une p-value faible parle de fiabilité statistique, jamais de l'ampleur de l'effet.

Fait main, en solo.

Si ce test t'a aidé, partage-le autour de toi : il peut débloquent un autre candidat. Et si tu veux que je traite un sujet précis, dis-le moi en commentaire : c'est là que je pioche mes prochains guides.

Dylan

