

25 contrôles qualité avant de livrer une analyse



Le contrôle, la méthode concrète pour le vérifier, et l'erreur réelle qu'il aurait attrapée.

La plupart des dashboards faux ne le sont pas à cause d'une formule ratée : ils sont faux parce que personne n'a vérifié le fichier source avant de le charger. Un audit de 10 minutes en amont évite un correctif de 2 heures une fois que le chiffre a déjà circulé en réunion. Note : les seuils statistiques cités (taux de manquants, IQR, z-score) sont des repères indicatifs, pas des normes absolues, et les exemples d'erreurs sont illustratifs.

Structure : le fichier tient-il debout ?

Avant tout calcul, on vérifie que le fichier lui-même est fiable : types, noms, format, identifiants.

1. Types cohérents avec le contenu réel

Méthode : Ouvrir chaque colonne et vérifier que le type déclaré (texte, nombre, date) correspond à ce qu'elle contient réellement, pas à ce que l'outil a deviné à l'import.

Erreur attrapée : `code_client` importé en nombre a perdu les zéros initiaux (00452 devenu 452), cassant toutes les jointures avec le système source.

2. Noms de colonnes normalisés et non ambigus

Méthode : Lister les en-têtes et repérer les noms vagues (`valeur`, `montant`, `date`) sans unité ni contexte, ou deux colonnes qui portent le même sens sous des libellés différents.

Erreur attrapée : deux colonnes `montant` et `montant_ht` coexistaient sans note ; un rapport a additionné les deux, doublant le chiffre d'affaires affiché.

3. Format de fichier et encodage corrects

Méthode : Vérifier l'encodage (UTF-8 attendu) et le séparateur avant tout chargement, surtout sur un export venant d'un outil différent de l'outil cible.

Erreur attrapée : un CSV exporté en Windows-1252 a transformé tous les « é » en caractères cassés dans les noms de villes, rendant les jointures géographiques muettes.

À retenir avant de charger un fichier

Le type déclaré et l'encodage ne sont pas des détails techniques : c'est la première ligne de défense contre un chiffre faux.

Réflexe

Ouvrir et lire avant de charger, jamais faire confiance à la détection automatique.

Risque ignoré

Un zéro perdu ou un accent cassé ne déclenche aucune erreur visible.

4. Identifiants uniques présents structurellement

Méthode : Confirmer qu'une colonne identifiant existe et n'est jamais vide avant de l'utiliser comme clé de jointure ou de déduplication.

Erreur attrapée : une table clients sans `id_client` renseigné sur 8% des lignes a forcé un rapprochement par nom, créant des doublons sur les homonymes.

Complétude : ce qui manque décide-t-il à ta place ?

Une valeur manquante n'est jamais neutre : elle disparaît d'un calcul sans jamais lever d'erreur.

5. Taux de valeurs manquantes global

Méthode : Calculer le pourcentage de cellules vides par colonne. Un taux au-dessus de 20% sur une colonne clé est un repère indicatif à examiner, pas un seuil absolu.

Erreur attrapée : une colonne `email` à 35% de vides n'avait pas été signalée; une campagne d'emailing a raté un tiers de la base sans que personne ne s'en aperçoive.

Excel, taux de manquants sur une colonne :

```
=NB.VIDE(A2:A500)/LIGNES(A2:A500)
```

6. Manquants concentrés sur une colonne critique

Méthode : Croiser le taux de manquants avec l'importance métier de la colonne : un champ secondaire vide est tolérable, un champ utilisé dans un calcul de KPI ne l'est pas.

Erreur attrapée : `date_signature` vide sur 12% des contrats a fait disparaître ces lignes d'un calcul de délai moyen, biaisant le résultat à la baisse sans erreur visible.

7. Cohérence des valeurs par défaut

Méthode : Vérifier si les vides sont codés de façons différentes (0, NULL, N/A, chaîne vide) dans la même colonne, ce qui fausse tout comptage de manquants.

Erreur attrapée : une colonne `remise` mélangeait 0 et cellules vides pour dire « pas de remise »; une moyenne ignorant les vides a donné une remise moyenne fausse.

Cohérence : les colonnes se contredisent-elles entre elles ?

Une donnée peut être valide colonne par colonne et fausse dès qu'on la regarde en relation avec les autres.

8. Unités homogènes (devises, mesures)

Méthode : Vérifier qu'une seule unité est utilisée par colonne : EUR partout et pas EUR mélangé à USD, kg partout et pas kg mélangé à g.

Erreur attrapée : un fichier consolidé multi-pays mélangeait EUR et USD dans `montant` sans colonne devise; le total consolidé a été additionné sans conversion.

9. Libellés et catégories : casse et doublons sémantiques PIÈGE CLASSIQUE

Méthode : Lister les valeurs distinctes d'une colonne catégorielle et repérer les variantes de casse ou d'espace avant tout regroupement.

Erreur attrapée : Paris, paris et Paris (espace final) comptaient comme 3 villes différentes dans un groupement, éclatant un total qui aurait dû être unique.

Excel, repérer casse et espaces en trop :

```
=EXACT(A2;B2)           // FAUX si la casse diffère  
=SUPPRESPE(A2)=A2      // FAUX si espaces en trop
```

10. Cohérence référentielle (clés étrangères valides) RUPTURE SILENCIEUSE

Méthode : Vérifier que chaque clé étrangère existe bien dans la table de référence avant de joindre, avec un RECHERCHEV ou un LEFT JOIN ... WHERE ref.id IS NULL.

Erreur attrapée : un lot de 40 commandes référençait un `id_produit` supprimé du catalogue; ces commandes disparaissaient silencieusement de tout rapport joint en INNER JOIN.

11. Cohérence inter-colonnes (ex. `date_fin` > `date_debut`)

Méthode : Contrôler les relations logiques attendues entre colonnes liées, pas seulement chaque colonne isolément.

Erreur attrapée : 6 contrats avaient une `date_fin` antérieure à `date_debut` suite à une saisie inversée, faussant tout calcul de durée moyenne d'engagement.

À retenir sur la cohérence

Une donnée peut être valide colonne par colonne et fautive dès qu'on la regarde en relation avec les autres.

Contrôle isolé

Chaque colonne semble correcte prise seule.

Contrôle croisé

Unité, casse, clé et dates ne se vérifient qu'ensemble.

Valeurs aberrantes : le chiffre est-il plausible ?

Un seuil statistique signale un candidat à vérifier, il ne remplace jamais le regard métier sur la donnée.

12. Bornes min/max plausibles métier

Méthode : Comparer le minimum et le maximum de chaque mesure à des bornes métier raisonnables (un âge de 140 ans, un prix négatif) plutôt qu'à une formule statistique.

Erreur attrapée : un champ `age_client` affichait un maximum de 999, valeur saisie par défaut par un formulaire mal configuré, gonflant l'âge moyen calculé.

13. Détection statistique (IQR ou z-score) PIÈGE CLASSIQUE

Méthode : Calculer l'écart interquartile (seuil indicatif à $1.5 \times \text{IQR}$) ou le z-score ($|z| > 3$ comme repère, pas une règle absolue) pour repérer les valeurs isolées.

Erreur attrapée : une commande à 850 000 euros, 100 fois la moyenne, était une erreur de saisie de virgule, repérée seulement après un calcul de z-score sur le montant.

Excel, bornes IQR et z-score (repères indicatifs) :

```
Q1 = QUARTILE(A2:A500;1)
Q3 = QUARTILE(A2:A500;3)
IQR = Q3-Q1
Borne basse = Q1-1.5*IQR / Borne haute = Q3+1.5*IQR

z = (A2-MOYENNE(A$2:A$500))/ECARTYPE(A$2:A$500)
```

14. Négatifs improbables sur une mesure positive

Méthode : Filtrer les valeurs négatives sur des colonnes qui ne devraient jamais l'être : quantité vendue, âge, durée.

Erreur attrapée : une `quantite` négative sur des lignes d'avoir mal étiquetées avait été additionnée telle quelle dans un total de ventes, le faisant baisser sans explication.

15. Distribution suspecte : valeur sentinelle

Méthode : Chercher des valeurs répétées de façon suspecte (9999, -1, 00/00/0000) qui signalent souvent un code technique plutôt qu'une vraie mesure.

Erreur attrapée : 9999 apparaissait 340 fois dans `delai_livraison_jours`, utilisé comme code « non renseigné » par l'ancien système, gonflant le délai moyen affiché.

À retenir sur les valeurs aberrantes

Un seuil statistique signale un candidat à vérifier, il ne remplace jamais le regard métier sur la donnée.

Borne métier

Toujours vérifier d'abord ce qui est plausible dans la vraie vie.

Seuil statistique

Un IQR ou un z-score oriente la recherche, il ne tranche pas seul.

Dates et temps : la chronologie tient-elle ?

Une date mal typée ou mal bornée fautive silencieusement toute tendance calculée dessus.

16. Format de date homogène

Méthode : Vérifier qu'une seule convention de date est utilisée (JJ/MM/AAAA partout), surtout sur des fichiers venant de systèmes ou de régions différentes.

Erreur attrapée : un export mélangeait MM/JJ/AAAA et JJ/MM/AAAA; toutes les dates du type 03/04/2025 étaient ambiguës entre le 3 avril et le 4 mars.

17. Plages temporelles cohérentes

Méthode : Vérifier qu'aucune date n'est dans le futur ni antérieure au lancement connu du système ou du produit.

Erreur attrapée : des dates de commande en 2039 provenaient d'un bug de saisie sur un champ libre, faussant une projection de tendance annuelle.

18. Granularité temporelle constante

Méthode : Vérifier qu'il n'existe pas de doublon de période, deux lignes pour le même mois sur le même client, qui romprait la granularité attendue de la table.

Erreur attrapée : une table mensuelle contenait deux lignes pour janvier 2025 sur un même client suite à une double extraction, doublant son chiffre dans l'agrégat annuel.

Doublons : la même chose comptée deux fois ?

Un doublon ne casse rien techniquement : il gonfle un total sans qu'aucune requête n'échoue.

19. Doublons exacts VOLUME GONFLÉ

Méthode : Compter les lignes strictement identiques sur toutes les colonnes.

Erreur attrapée : un export relancé deux fois avait ajouté 1200 lignes identiques à la table, doublant artificiellement le volume de ventes du mois.

Doublons exacts, Excel et SQL :

Excel : `=NB.SI.ENS(A:A;A2;B:B;B2)>1`

SQL :
`SELECT col1, col2, COUNT(*)`
`FROM table`
`GROUP BY col1, col2`
`HAVING COUNT(*) > 1`

20. Doublons quasi identiques (variantes de nom)

Méthode : Rapprocher les libellés proches, fautes de frappe et abréviations, plutôt que de se fier à une égalité stricte.

Erreur attrapée : « Ste Générale » et « Société Générale » comptaient comme deux clients distincts, éclatant le chiffre d'affaires d'un même compte en deux lignes.

21. Doublons sur clé primaire supposée

Méthode : Vérifier qu'une colonne censée être unique, comme un identifiant ou une référence, ne contient aucune valeur répétée.

Erreur attrapée : `id_commande` contenait 15 doublons issus d'une réinitialisation de compteur après une migration, faisant écraser des lignes lors d'une jointure.

Excel, unicité d'une clé supposée primaire :

`=SOMMEPROD((A$2:A$500=A2)*1)>1`

Source et traçabilité : peux-tu défendre ce chiffre ?

Un chiffre juste sans traçabilité reste un chiffre qu'on ne peut ni défendre ni reproduire.

22. Origine documentée (système source, extraction)

Méthode : Demander et noter d'où vient le fichier : quel système, quel export, quel filtre a déjà été appliqué avant de l'utiliser dans une analyse.

Erreur attrapée : un fichier « ventes » reçu par email sans origine notée s'est révélé être un extrait filtré sur une seule région, faussant une comparaison nationale.

23. Date de dernière mise à jour connue

Méthode : Vérifier la date d'actualisation du fichier ou de la table avant de la présenter comme à jour dans un rapport.

Erreur attrapée : un tableau de bord affichait un stock non actualisé depuis 3 semaines, utilisé pour une décision de réassort qui a créé une rupture.

24. Méthode de collecte ou de transformation tracée ÉCART INEXPLICABLE

Méthode : Documenter les étapes de nettoyage appliquées, filtres, jointures, exclusions, pour que le résultat soit explicable si quelqu'un le remet en question.

Erreur attrapée : un filtre d'exclusion des tests internes avait été appliqué puis oublié dans la documentation, rendant un écart de -8% inexplicable en réunion.

À retenir sur la source

Un chiffre juste sans traçabilité reste un chiffre qu'on ne peut pas défendre ni reproduire.

Sans trace

Le chiffre s'effondre à la première question « d'où ça vient ? »

Avec trace

Origine, date, filtres et script permettent de le rejouer et de le défendre.

25. Reproductibilité : script ou requête versionnés

Méthode : Garder la requête ou le script qui a produit le résultat, versionné, plutôt qu'un calcul fait à la main dans une feuille non traçable.

Erreur attrapée : un chiffre présenté en comité n'a pas pu être recalculé un mois plus tard, la feuille source ayant été modifiée entre-temps sans trace de la version d'origine.

Les 25 contrôles en un tableau : la question réflexe par famille

Structure (C01-C04)	Le type, le nom et l'encodage de chaque colonne sont-ils fiables avant chargement ?
Complétude (C05-C07)	Ce qui manque a-t-il été mesuré, et concentré sur une colonne qui compte ?
Cohérence (C08-C11)	Les colonnes se contredisent-elles entre elles une fois croisées ?
Valeurs aberrantes (C12-C15)	Le chiffre est-il plausible métier avant d'être plausible statistiquement ?
Dates/temps (C16-C18)	Le format, la plage et la granularité des dates sont-ils constants ?
Doublons (C19-C21)	La même réalité est-elle comptée une seule fois ?
Source (C22-C25)	Peux-tu dire d'où vient ce chiffre, et le reproduire ?

25 sur 25. Tu n'as pas besoin de tous les cocher à la main sur chaque livraison. Tu dois surtout garder le réflexe : avant de partager un chiffre, demande-toi de quelle famille de risque il pourrait souffrir. C'est ce réflexe, pas la liste, qui fait la différence entre un analyste junior et un analyste de confiance.

Fait main, en solo.

Si cet audit t'a aidé, partage-le autour de toi : il peut éviter un correctif de dernière minute à un autre analyste. Et si tu veux que je traite un sujet précis, dis-le moi en commentaire : c'est là que je pioche mes prochains guides.

Dylan

