

20 questions stats

Le socle Data Analyst /20



Avant de te dire junior en stats. Durée conseillée : 20 min · 3 niveaux · corrigé détaillé.

Objectif : vérifier tes réflexes statistiques sur des cas concrets, pas des définitions apprises par coeur. En entretien, je vois trop de candidats confondre moyenne et médiane sur un salaire, ou lire un r de 0,9 comme une preuve de causalité. Ce test cherche ces réflexes.

Repères : 10/20 = bases à revoir, 16/20 = réflexes solides.

Candidat _____ Date _____ Note _____ /20

Niveau 1 : tendance centrale.

Six questions pour vérifier si tu sais choisir entre moyenne, médiane et mode selon le terrain.

Question 1. Dans une PME de 9 personnes, 8 employés gagnent chacun environ 2 800€ net par mois, et le dirigeant gagne 15 000€. Le RH annonce fièrement « salaire moyen : 4 156€ ». Quelle mesure représente le mieux le salaire typique de l'équipe ?

- a) La médiane, car elle n'est pas tirée vers le haut par le dirigeant.
- b) La moyenne, car elle utilise toutes les valeurs.
- c) Le mode, car il apparaît le plus souvent.
- d) L'écart-type, car il mesure la dispersion.

Question 2. Un manager affirme : « le salaire moyen de l'équipe est de 4 156€, donc la plupart des employés gagnent autour de 4 156€ ». Où est l'erreur de raisonnement ?

- a) Il n'y a pas d'erreur, la moyenne représente toujours le groupe.
- b) La moyenne est tirée vers le haut par le salaire du dirigeant; la plupart des employés gagnent bien moins.
- c) Il aurait dû utiliser le mode à la place.
- d) Le calcul de la moyenne est faux.

Question 3. Que mesure l'écart-type d'une série de valeurs ?

- a) La valeur centrale de la série.
- b) La valeur la plus fréquente.
- c) La dispersion des valeurs autour de la moyenne.
- d) Le pourcentage de valeurs supérieures à la moyenne.

Question 4. Un sondage relève l'âge de 7 clients : 24, 29, 24, 31, 24, 45, 29. Quel est le mode de cette série ?

- a) 29 ans, la moyenne arrondie.
- b) 31 ans, la médiane.
- c) 45 ans, la valeur la plus élevée.
- d) 24 ans, la valeur qui revient le plus souvent (trois fois).

Question 5. Tu dois résumer le temps de trajet domicile-travail d'une équipe de 12 personnes. Onze mettent entre 20 et 35 minutes, une personne fait 2h de train. Quelle mesure choisir pour représenter le trajet typique ?

- a) La médiane, moins sensible à la valeur extrême.
- b) La moyenne, plus simple à calculer.
- c) L'écart-type, qui gomme l'effet de l'outlier.
- d) Le mode, car il existe toujours une valeur dominante.

Question 6. Voici les notes d'un test pour 6 candidats : 12, 14, 14, 16, 18, 20. Quelle est la médiane ?

- a) 14
- b) 15
- c) 16
- d) 14,5

Niveau 2 : pourcentages et dispersion.

Sept questions où le chiffre semble juste, mais où la base ou l'échantillon changent tout.

Question 7. Un taux de conversion passe de 40% à 50%. De combien a-t-il augmenté en variation relative ?

- a) +10%
- b) +20%
- c) +25%
- d) +50%

Question 8. Le taux de churn passe de 10% à 15%. Un rapport titre « le churn a augmenté de 5% ». Quelle est l'erreur ?

- a) Il n'y a pas d'erreur, 15 moins 10 égale 5.
- b) Le calcul est faux, l'augmentation réelle est de 50 points.
- c) On ne peut pas comparer deux pourcentages entre eux.
- d) Le churn a augmenté de 5 points de pourcentage, soit +50% en variation relative.

Question 9. Un post LinkedIn affiche « 100% de nos testeurs recommandent le produit ! ». Le sondage a été réalisé auprès de 3 personnes. Quel est le problème principal ?

- a) La base est trop petite pour être représentative : le taux peut changer radicalement avec un testeur de plus.
- b) Un taux de 100% est statistiquement impossible.
- c) Il fallait utiliser la médiane plutôt qu'un pourcentage.
- d) Il fallait convertir le pourcentage en points de pourcentage.

Question 10. Les ventes hebdomadaires d'un produit sur 8 semaines : 40, 42, 43, 45, 46, 48, 50, 95 (en k€). Le premier quartile Q1 est 42,5 et le troisième quartile Q3 est 49. Quel est l'écart interquartile (IQR) et que suggère-t-il sur la valeur 95 ?

- a) IQR = 91,5 ; 95 est une valeur normale.
- b) IQR = 6,5 ; 95 dépasse largement le seuil $Q3 + 1,5 \times IQR$, c'est un candidat outlier.
- c) IQR = 6,5 ; 95 est proche de la moyenne, donc pas un outlier.
- d) IQR ne peut pas être calculé sur des ventes.

Question 11. Un produit A est noté 4,8/5 par 5 clients, un produit B est noté 4,2/5 par 500 clients. Le catalogue affiche « note moyenne du magasin : 4,5/5 » en faisant la moyenne simple des deux notes. Quelle est l'erreur ?

- a) Il fallait utiliser la médiane des deux notes.
- b) Il n'y a pas d'erreur, la moyenne simple est toujours correcte.
- c) La moyenne simple ignore le nombre d'avis ; une moyenne pondérée par le volume d'avis donnerait un résultat bien plus proche de 4,2.
- d) Il fallait utiliser l'écart-type des deux notes.

Question 12. Une startup teste une nouvelle interface auprès de 5 utilisateurs : 4 préfèrent la nouvelle version. Elle conclut « 80% des utilisateurs préfèrent la V2, on déploie à tous ». Que faut-il vérifier avant de généraliser ?

- a) Rien, 80% est un résultat suffisant pour trancher.
- b) Que la moyenne des préférences est calculée correctement.
- c) Que le mode des préférences a été utilisé.
- d) Que la taille de l'échantillon (5 personnes) est assez grande pour représenter l'ensemble des utilisateurs.

Question 13. Deux équipes commerciales ont la même moyenne de ventes mensuelles (50k€). L'équipe A varie entre 45k et 55k selon les mois, l'équipe B varie entre 10k et 90k. Quelle équipe a l'écart-type le plus élevé ?

- a) L'équipe B, car ses valeurs sont plus dispersées autour de la moyenne.
- b) L'équipe A, car ses valeurs sont proches de la moyenne.
- c) Les deux équipes ont le même écart-type puisque la moyenne est identique.
- d) On ne peut pas comparer l'écart-type de deux équipes différentes.

Niveau 3 : corrélation et pièges de lecture.

Sept questions pour repérer quand un chiffre correct raconte quand même la mauvaise histoire.

Question 14. Une étude montre que les mois où les ventes de glaces augmentent, les noyades augmentent aussi. Un article titre « manger des glaces cause des noyades ». Quelle est l'erreur de raisonnement ?

- a) Il n'y a pas d'erreur, la corrélation prouve la causalité.
- b) Les deux variables sont corrélées à cause d'une troisième variable (la chaleur estivale), pas d'un lien de cause à effet direct.
- c) Il fallait utiliser l'écart-type pour prouver la causalité.
- d) La corrélation est probablement mal calculée.

Question 15. Un data analyst calcule un coefficient de corrélation $r = 0,04$ entre le budget marketing et les ventes, et conclut « il n'y a aucun lien entre les deux ». En traçant le nuage de points, on voit une courbe en U bien nette. Quelle est l'erreur ?

- a) Il n'y a pas d'erreur, un r proche de 0 signifie toujours l'absence de lien.
- b) Le calcul du r est probablement faux.
- c) Le coefficient de corrélation (Pearson) ne détecte que les relations linéaires; une relation non linéaire peut exister malgré un r proche de 0.
- d) Il fallait utiliser la médiane du budget plutôt que r .

Question 16. Dans un service, le salaire moyen est de 3 400€ et le salaire médian est de 3 000€. Que suggère cet écart sur la forme de la distribution ?

- a) La distribution est symétrique.
- b) La distribution est asymétrique à gauche.
- c) Les deux mesures devraient toujours être égales, il y a une erreur de calcul.
- d) La distribution est asymétrique à droite : quelques hauts salaires tirent la moyenne vers le haut.

Question 17. Deux campagnes marketing ont chacune un meilleur taux de conversion que l'autre, sur mobile et sur desktop pris séparément. Pourtant, sur le total agrégé, la deuxième campagne semble meilleure. Comment est-ce possible ?

- a) C'est le paradoxe de Simpson : la répartition du trafic entre mobile et desktop diffère entre les deux campagnes et inverse la tendance globale.
- b) C'est une erreur de calcul, ce cas est mathématiquement impossible.
- c) La corrélation entre mobile et desktop explique l'écart.
- d) L'écart-type des deux campagnes doit être identique pour comparer.

Question 18. Sur 5 ventes d'un vendeur : 200€, 210€, 195€, 205€, 5 000€ (une vente exceptionnelle). Un manager retire la vente de 5 000€ pour recalculer les stats. Que se passe-t-il ?

- a) La médiane change fortement, la moyenne ne bouge pas.
- b) La moyenne change fortement (de 1 162€ à 202,5€), la médiane change à peine (de 205€ à 202,5€).
- c) La moyenne et la médiane changent de la même façon.
- d) Ni la moyenne ni la médiane ne changent.

Question 19. Tu dois présenter le temps de résolution typique d'un ticket support pour 30 tickets, dont 27 résolus en moins de 2h et 3 tickets bloqués plus de 48h chacun. Quelle mesure choisir pour ne pas déformer la réalité vécue par la majorité des clients ?

- a) La moyenne, car elle prend en compte tous les tickets.
- b) L'écart-type, qui donne une idée du temps typique.
- c) La médiane, qui reflète le temps vécu par la majorité sans être écrasée par les 3 tickets extrêmes.
- d) Le mode, qui n'est pas calculable sur des durées.

Question 20. Un analyste junior présente : « $r = 0,93$ entre le nombre de tasses de café bues au bureau et la productivité de l'équipe, on va donc doubler le budget café pour booster la productivité ». Quel est le principal problème de cette recommandation ?

- a) Un r de 0,93 est trop faible pour agir.
- b) Il fallait utiliser le mode du nombre de tasses.
- c) La productivité ne peut pas être mesurée statistiquement.
- d) Une corrélation forte n'établit pas de causalité ; d'autres facteurs (charge de travail, saison, effectifs) peuvent expliquer les deux variables.

Solutions et explications.

Un point par bonne réponse. Compte ton score, puis relis surtout celles que tu ne peux pas expliquer à voix haute.

1. **a)** La médiane sépare la série en deux moitiés égales et ignore l'ampleur des valeurs extrêmes; le piège est de croire que la moyenne représente toujours le groupe.
2. **b)** Le dirigeant à 15 000€ tire la moyenne bien au-dessus de ce que gagnent réellement 8 des 9 personnes; c'est l'erreur classique de confondre moyenne et « valeur typique ».
3. **c)** L'écart-type quantifie la dispersion autour de la moyenne; le piège est de le confondre avec une mesure de position comme la médiane.
4. **d)** Le mode est la valeur la plus fréquente (24 apparaît trois fois), pas la moyenne ni la médiane; les confondre est l'erreur la plus courante sur cette notion.
5. **a)** La médiane n'est pas déformée par la valeur extrême de 2h de train; la moyenne, elle, serait tirée artificiellement vers le haut.
6. **b)** Avec un nombre pair de valeurs, la médiane est la moyenne des deux valeurs centrales : $(14+16)/2 = 15$; oublier ce cas pair est le piège classique.
7. **c)** La variation relative se calcule par rapport au point de départ : $(50-40)/40 = 25\%$, pas la simple différence en points.
8. **d)** 10 et 15 sont des pourcentages : leur différence se lit en points de pourcentage (+5 pts), tandis que la variation relative est de +50%; confondre les deux est l'erreur la plus fréquente en reporting.
9. **a)** Avec seulement 3 répondants, chaque personne pèse 33% du résultat; le taux n'est pas fiable et peut s'effondrer avec un échantillon plus large.
10. **b)** $IQR = Q3 - Q1 = 6,5$; le seuil d'outlier classique est $Q3 + 1,5 \times IQR = 58,75$, largement dépassé par 95, qui est donc un candidat outlier à examiner.
11. **c)** Une moyenne simple donne le même poids à 5 avis qu'à 500; la moyenne pondérée par le volume reflète bien mieux la réalité du magasin, proche de la note du produit B.
12. **d)** 5 personnes ne permettent pas de généraliser un comportement à toute la base; le piège est de traiter un pourcentage impressionnant comme une preuve statistique.
13. **a)** L'écart-type mesure l'étalement des valeurs autour de la moyenne : l'équipe B, plus volatile (10k à 90k), a un écart-type nettement plus élevé malgré une moyenne identique.
14. **b)** La chaleur estivale explique à la fois les ventes de glaces et les baignades (donc les noyades); corrélation n'est pas causalité, le piège classique du « facteur caché ».
15. **c)** Le coefficient de Pearson ne capture que les relations linéaires; une relation en U ou en cloche peut coexister avec un r proche de 0, d'où l'intérêt de toujours tracer le nuage de points.
16. **d)** Quand la moyenne dépasse nettement la médiane, la distribution est étirée vers la droite par quelques valeurs hautes; c'est un skew positif classique sur les salaires.
17. **a)** Le paradoxe de Simpson survient quand la répartition des sous-groupes (ici mobile/desktop) diffère fortement entre les deux campagnes, inversant la conclusion au niveau agrégé.
18. **b)** La moyenne est très sensible aux valeurs extrêmes (elle chute de 1 162€ à 202,5€ dès qu'on retire l'outlier), alors que la médiane, robuste, ne bouge presque pas.
19. **c)** La médiane n'est pas écrasée par les 3 tickets bloqués 48h; la moyenne donnerait un temps « typique » totalement irréaliste pour la majorité des clients.
20. **d)** Une corrélation forte, même à 0,93, ne prouve rien sur la cause; charge de travail, saison ou effectifs peuvent expliquer conjointement le café et la productivité, le piège classique de la confusion corrélation/causalité.

Fait main, en solo.

Si ce test t'a aidé, partage-le autour de toi : il peut débloquent un autre candidat. Et si tu veux que je traite un sujet précis, dis-le moi en commentaire : c'est là que je pioche mes prochains guides.

Dylan

