

5 datasets moches pour arrêter les tutos



Les tutos te donnent des données déjà propres. Le terrain, lui, ne te fait jamais ce cadeau.

Tu peux enchaîner les cours en ligne pendant six mois et arriver en poste sans avoir jamais ouvert un fichier vraiment sale. Ce guide te donne 5 jeux de données publics et connus, avec leur défaut réel et une consigne d'exercice précise. Pas de notebook propre à recopier : un problème à comprendre, et un livrable à produire toi-même.

Le terrain, pas la démo.

Un tuto te donne un CSV propre pour que tu apprennes la syntaxe. Un vrai fichier arrive avec ses dates cassées, ses valeurs manquantes et ses colonnes mal typées : c'est ça que tu dois savoir lire.

1. Olist, e-commerce brésilien JOINTURES

Le problème : Dataset public bien connu (Kaggle) : commandes, articles, paiements et avis client vivent dans plusieurs tables séparées, à joindre proprement. Chaque commande porte cinq dates différentes (achat, paiement approuvé, remise au transporteur, livraison, livraison estimée), et les avis sont en texte libre en portugais. La difficulté n'est pas la syntaxe du JOIN, c'est de choisir la bonne date et de ne pas dupliquer les lignes en cours de route.

Ce que tu dois produire

Compétence

Joindre sans dupliquer, choisir la bonne colonne de date.

Exercice

Reconstitue le délai réel de livraison (date de livraison moins date d'achat) et repère les commandes sans ligne de paiement associée.

Livrable

Une table avec la colonne de délai, plus la liste des commandes orphelines de paiement.

2. Inside Airbnb, une ville

Le problème : Extraction publique bien connue des annonces d'une ville : la colonne de prix est stockée en texte, avec le symbole monétaire et parfois un séparateur de milliers collés au chiffre. D'autres colonnes mélangent les types (un taux de réponse écrit en pourcentage texte), et les scores d'avis manquent sur une partie des annonces récentes. Rien ne casse à l'ouverture du fichier : le piège, c'est de calculer une moyenne sur une colonne encore en texte sans t'en rendre compte.

Ce que tu dois produire

Compétence

Caster un texte numérique sale, choisir une stratégie sur les valeurs manquantes.

Exercice

Nettoie **price** (retire le symbole et le séparateur avant de caster en nombre), puis calcule le prix médian par quartier.

Livrable

Un tableau prix médian par quartier, avec une ligne notant les quartiers trop incomplets pour être fiables.

3. NYC Taxi trips VALEURS ABERRANTES

Le problème : Historique public des courses de taxi new-yorkaises : gros volume, et une partie des lignes porte des coordonnées de prise en charge situées hors de la ville, voire dans l'océan. Certaines durées de trajet sont négatives ou dépassent plusieurs heures pour quelques kilomètres, signe d'un souci de capteur ou de saisie, pas d'un vrai trajet. Aucune de ces lignes n'est un NaN : elles ont une valeur, juste une valeur fausse. C'est ça qui rend le nettoyage plus dur qu'un simple `dropna()`.

```
-- filtre de santé avant toute analyse de duree
SELECT *
FROM trips
WHERE pickup_lat BETWEEN 40.4 AND 41.0
      AND pickup_lng BETWEEN -74.3 AND -73.6
      AND trip_duration_s BETWEEN 30 AND 7200;
```

Ce que tu dois produire

Compétence

Définir un seuil réaliste plutôt que faire confiance à la valeur brute.

Exercice

Filtre les trajets hors zone et les durées impossibles (négatives ou absurdes), puis regarde la distribution des durées restantes.

Livrable

Ta règle de filtre écrite noir sur blanc, plus le pourcentage de lignes écartées, communicable en une phrase.

À retenir avant de choisir ton dataset

Le nettoyage n'est pas une seule compétence : joindre sans dupliquer, caster un texte sale, ou filtrer une valeur aberrante sont trois réflexes différents. Un tuto qui te donne toujours le même exercice ne t'en apprend qu'un.

Le repère utile : avant d'écrire une ligne de code, demande-toi si le problème est structurel (jointure, type de colonne) ou statistique (valeur plausible ou non). Ça change la correction que tu vas appliquer.

4. data.gouv.fr, un export administratif

Le problème : Export public d'une administration française : fichier enregistré en Latin-1 alors que ton environnement lit de l'UTF-8 par défaut, séparateur point-virgule au lieu de la virgule attendue, et parfois un en-tête réparti sur deux lignes. Les accents se transforment en caractères bizarres si l'encodage n'est pas déclaré au chargement. Rien ne plante forcément, mais tes noms de colonnes deviennent inexploitable en l'état.

Ce que tu dois produire

Compétence

Déclarer explicitement encodage et séparateur, normaliser des libellés.

Exercice

Charge le fichier sans accent cassé, puis construis une table de correspondance nom d'origine vers nom normalisé (minuscules, sans accent, sans espace).

Livrable

La liste des colonnes normalisées, réutilisable comme convention dans un README.

5. Titanic, en mode audit qualité

Le problème : Le dataset le plus joué du machine learning débutant, mais ici on ne cherche pas un score de prédiction : on l'audite. La colonne **Age** manque sur une part significative des passagers, la colonne **Cabin** manque presque partout, et plusieurs colonnes catégorielles (classe, sexe, port d'embarquement) doivent être encodées avant tout modèle. Le piège junior classique : appliquer un `dropna()` global qui supprime discrètement une bonne partie du jeu de données.

Ce que tu dois produire

Compétence

Choisir une stratégie de valeurs manquantes colonne par colonne, pas une règle unique.

Exercice

Pour **Age**, justifie une imputation (par exemple par médiane croisée classe/sexe) plutôt qu'une suppression. Pour **Cabin**, décide entre garder un indicateur binaire « a une cabine connue » ou supprimer la colonne.

Livrable

Une note d'audit courte : colonne, pourcentage manquant, décision, justification en une phrase. Réutilisable telle quelle dans un portfolio.

5 datasets, 5 réflexes différents : jointure sans doublon, cast d'un texte numérique sale, filtre sur une valeur aberrante, encodage et libellés, stratégie de valeurs manquantes assumée. Tu n'as pas besoin de les traiter dans l'ordre ni le même jour. Choisis-en un, produis le livrable demandé, et compare ta version à ce que tu ferais aujourd'hui sur un vrai fichier client : c'est cet écart qui te dit où tu en es vraiment.

Fait main, en solo.

Si ce guide t'a donné envie de salir tes mains sur un vrai fichier, partage-le à quelqu'un qui enchaîne encore les notebooks tout propres. Et si tu veux le prochain dataset moche à décortiquer, dis-le moi en commentaire.

Dylan

