

Test corrélation

20 questions /20



Le piège business classique : les conclusions bancales à repérer avant qu'elles partent en comité. Durée conseillée : 20 min · 3 paliers · corrigé détaillé.

Objectif : vérifier si tu sais repérer une conclusion causale bancale derrière une simple corrélation. Observation terrain Datafuji : c'est la faute la plus fréquente vue en début de mission chez un client, une coïncidence temporelle vendue comme une preuve.

Repères : 12/20 = tu évites le pire, 17/20 = profil qu'on garde pour lire un dashboard sans se faire avoir.

Candidat _____ Date _____ Note _____ /20

Palier 1 : corrélation $\neq$ causalité.

Six questions pour poser le réflexe de base : une corrélation observée n'est jamais une preuve toute seule.

Question 1. Une corrélation entre deux variables signifie, concrètement, que :

- a) X et Y bougent souvent ensemble, sans que ça prouve que l'un cause l'autre.
- b) X cause forcément Y.
- c) X et Y sont mesurés au même moment, donc reliés par nature.
- d) Il existe une loi mathématique exacte entre X et Y.

Question 2. « Le CA monte quand on envoie plus d'emails, donc les emails font vendre. » Quelle lecture est correcte ?

- a) C'est prouvé, il faut envoyer plus d'emails.
- b) Corrélation observée, mais il faut vérifier si une autre cause pousse les deux à la fois (ex. période de soldes).
- c) Aucune corrélation n'existe ici.
- d) Le CA cause le volume d'emails envoyés.

Question 3. Les ventes de glaces et les noyades augmentent ensemble chaque été. Quelle est la meilleure explication ?

- a) Manger des glaces cause les noyades.
- b) Les noyades poussent les gens à acheter des glaces.
- c) La chaleur, variable cachée, augmente à la fois les ventes de glace et la fréquentation des plages et piscines.
- d) C'est une coïncidence pure, sans aucune explication possible.

Question 4. Un rapport écrit : « Les clients qui ouvrent nos emails achètent 3 fois plus, donc les emails multiplient les ventes par 3. » Qu'est-ce qui cloche ?

- a) Rien, le calcul est juste et prouve la causalité.
- b) Il faudrait tripler le nombre d'emails envoyés pour confirmer.
- c) Le chiffre 3x est statistiquement impossible à obtenir.
- d) Les clients qui ouvrent les emails sont probablement déjà plus engagés : c'est une corrélation, pas une preuve que l'email cause l'achat.

Question 5. « Les commerciaux qui utilisent le plus le CRM vendent plus, donc forcer l'usage du CRM va augmenter les ventes. » Quel est le risque de cette conclusion ?

- a) Les meilleurs vendeurs adoptent spontanément plus le CRM parce qu'ils sont organisés : la performance explique l'usage, pas l'inverse.
- b) Le CRM cause à coup sûr la performance.
- c) Il faut réduire l'usage du CRM pour tester.
- d) Aucun lien n'existe entre CRM et performance.

Question 6. Quelle phrase résume le mieux la règle à retenir sur corrélation et causalité ?

- a) Une corrélation forte suffit toujours à agir.
- b) Une corrélation observée est un signal à creuser, pas une preuve : il faut chercher la cause commune ou tester activement.
- c) Seule la significativité statistique compte.
- d) La causalité ne s'établit jamais, même avec un test contrôlé rigoureux.

Palier 2 : les variables cachées.

Sept questions sur les confounders, le paradoxe de Simpson, le biais de sélection et la causalité inverse : là où le rapport a l'air propre mais ne l'est pas.

Question 7. Un produit a un meilleur taux de conversion que son concurrent sur mobile ET sur desktop pris séparément, mais un taux de conversion global plus bas une fois les deux canaux regroupés. Comment est-ce possible ?

- a) C'est forcément une erreur de calcul.
- b) Impossible : il y a nécessairement une seule bonne réponse.
- c) Le paradoxe de Simpson : la répartition du trafic entre les deux canaux diffère et fausse la moyenne globale.
- d) Le concurrent a triché sur ses chiffres.

Question 8. On trouve une corrélation impressionnante entre le nombre de tasses de café bues au bureau et le chiffre d'affaires mensuel sur 3 ans. Que doit faire un analyst sérieux ?

- a) Recommander d'acheter plus de café immédiatement.
- b) Publier le résultat comme preuve de causalité.
- c) Ignorer la question : la corrélation suffit en soi.
- d) Chercher une explication de fond ou traiter cette corrélation comme fallacieuse (spurious) tant qu'aucun mécanisme causal n'est identifié.

Question 9. Une variable cachée (lurking variable) est :

- a) Un facteur non mesuré qui influence à la fois X et Y et explique leur lien apparent.
- b) La variable qu'on choisit de mettre en abscisse sur un graphique.
- c) Un synonyme de variable dépendante.
- d) Une erreur de saisie dans les données.

Question 10. Les utilisateurs qui utilisent une fonctionnalité avancée restent plus longtemps abonnés. L'équipe veut pousser tout le monde vers cette fonctionnalité pour réduire le churn. Quel est le risque ?

- a) Aucun : la fonctionnalité cause forcément la rétention.
- b) Les utilisateurs déjà engagés sont peut-être ceux qui explorent naturellement cette fonctionnalité : c'est l'engagement qui explique l'usage, pas l'inverse.
- c) Il faut désactiver la fonctionnalité pour vérifier.
- d) Le churn ne dépend jamais des fonctionnalités du produit.

Question 11. Un rapport note que les magasins avec un vigile ont plus de vols détectés que ceux sans vigile, et conclut que les vigiles provoquent les vols. Quelle est la faille ?

- a) Aucune, la statistique est solide.
- b) Il faut renvoyer tous les vigiles immédiatement.
- c) Les magasins à haut risque (zone, valeur du stock) embauchent plus souvent un vigile ET détectent plus de vols : le niveau de risque est la variable cachée.
- d) Les vigiles falsifient les chiffres de vol.

Question 12. Une étude interne sur les clients qui répondent à un sondage de satisfaction montre 95% de satisfaits. Le marketing conclut que le produit est excellent. Quel biais menace cette conclusion ?

- a) Aucun, l'échantillon est fiable par nature.
- b) Le paradoxe de Simpson.
- c) La régression vers la moyenne.
- d) Un biais de sélection : les clients mécontents ont souvent déjà quitté ou ignorent le sondage, l'échantillon surreprésente les satisfaits.

Question 13. Face à une corrélation surprenante entre deux métriques business, quel réflexe protège le mieux d'une fausse conclusion ?

- a) Chercher activement une variable cachée plausible ou un biais de sélection avant de parler de cause.
- b) Communiquer le chiffre tel quel, car le board veut une histoire simple.
- c) Multiplier les tests jusqu'à trouver une corrélation significative.
- d) Se fier uniquement au coefficient de corrélation : plus il est proche de 1, plus c'est causal.

Palier 3 : les pièges d'échantillon et de lecture.

Sept questions sur le taux de base, la régression vers la moyenne, l'échantillon trop petit, le p-hacking et l'A/B test mal lu : là où se joue le 17/20.

Question 14. Un modèle de détection de fraude affiche 99% de précision, mais la fraude réelle ne concerne que 0,1% des transactions. Pourquoi la plupart des alertes peuvent quand même être des faux positifs ?

- a) 99% de précision élimine mathématiquement les faux positifs.
- b) Le taux de base (base rate) très faible de la fraude fait que même un excellent modèle génère plus de fausses alertes que de vraies, en valeur absolue.
- c) Le modèle est forcément mal codé.
- d) Il faut baisser le seuil de détection à 50%.

Question 15. Les 10 magasins les moins performants du trimestre reçoivent un coaching, et le trimestre suivant leurs résultats s'améliorent nettement. Le directeur en conclut que le coaching marche. Quel biais faut-il envisager avant de conclure ?

- a) Le biais de sélection uniquement.
- b) Le paradoxe de Simpson.
- c) La régression vers la moyenne : des résultats extrêmement bas ont statistiquement tendance à remonter tout seuls vers la moyenne, coaching ou pas.
- d) Aucun biais : l'amélioration prouve l'effet du coaching.

Question 16. Un A/B test tourne 2 jours sur 40 visiteurs et affiche un variant B à +25% de conversion. L'équipe veut le déployer partout dès demain. Quel est le problème principal ?

- a) 40 visiteurs, c'est toujours suffisant pour un test fiable.
- b) Le variant B est forcément le bon puisque le pourcentage est positif.
- c) Il faut changer le nom du variant.
- d) L'échantillon est trop petit : le résultat peut n'être que du bruit statistique qui disparaîtra sur un volume plus large.

Question 17. Un analyst teste 20 segments de clients différents et trouve qu'un seul segment montre un effet significatif à $p < 0,05$ sur une campagne. Il le présente comme la découverte clé. Quel est le piège ?

- a) Avec 20 tests, un résultat significatif par hasard est probable même sans effet réel : c'est un problème de comparaisons multiples (p-hacking).
- b) Un $p < 0,05$ est toujours une preuve solide, peu importe le nombre de tests menés.
- c) Il fallait tester encore plus de segments pour être sûr.
- d) Le seuil de 0,05 est trop strict et devrait être supprimé.

Question 18. L'équipe regarde les résultats du test A/B chaque matin et arrête le test dès que le variant B repasse devant, après 3 jours. Quel est le risque de cette méthode ?

- a) Aucun, regarder souvent accélère juste la décision.
- b) Le fait de s'arrêter dès qu'un résultat favorable apparaît (peeking) gonfle le risque de conclure à tort qu'il y a un effet, alors que ce n'est que du bruit.
- c) Il faut au contraire ne jamais regarder les résultats, même après la fin du test.
- d) 3 jours est toujours suffisant pour un test A/B, quel que soit le trafic.

Question 19. Le panier moyen augmente sur chaque segment de clients pris séparément (nouveaux et fidèles), mais le panier moyen global de l'entreprise baisse ce trimestre. Comment est-ce possible sans erreur de calcul ?

- a) C'est mathématiquement impossible, il y a forcément une erreur.
- b) Le panier moyen ne peut jamais baisser si chaque segment monte.
- c) Un effet de composition (mix shift) : la part des nouveaux clients, qui dépensent moins, a augmenté dans le mix global, ce qui tire la moyenne globale vers le bas.
- d) Les segments ont été mal définis dès le départ.

Question 20. « Le CA a augmenté le mois où on a changé le logo du site, donc le nouveau logo a fait vendre. » Ce type de conclusion revient très souvent en début de mission chez un client. Quelle réponse d'analyste est la plus solide ?

- a) Valider la conclusion : la coïncidence temporelle suffit.
- b) Rejeter le logo comme cause possible sans aucune vérification.
- c) Demander un budget pour changer le logo tous les mois.
- d) Vérifier s'il y a eu d'autres changements ce mois-là (saisonnalité, promo, trafic) avant d'attribuer la hausse au logo, et tester en A/B si possible.

Solutions et explications.

Un point par bonne réponse. Compte ton score, puis relis surtout les pièges que tu n'aurais pas su nommer à voix haute.

1. **a)** Une corrélation dit seulement que deux variables bougent ensemble; elle ne dit rien sur la cause. C'est la confusion de base à corriger en premier.
2. **b)** Le piège est la conclusion hâtive : une hausse conjointe (emails, CA) appelle une vérification de cause commune, pas une action immédiate.
3. **c)** Piège classique de variable cachée : la chaleur explique les deux hausses; ni les glaces ni les noyades ne se causent entre elles.
4. **d)** Le piège est de confondre engagement préexistant et effet de l'email : les ouvriers étaient probablement déjà plus enclins à acheter.
5. **a)** Piège de causalité inverse : c'est la performance qui pousse à l'usage du CRM, pas l'usage qui crée la performance.
6. **b)** La règle générale à retenir pour tout le test : corrélation observée égale signal à creuser, jamais preuve suffisante.
7. **c)** Paradoxe de Simpson : une répartition de trafic différente entre mobile et desktop peut inverser la tendance une fois les canaux agrégés.
8. **d)** Corrélation fallacieuse (spurious) : sur des séries longues, des coïncidences statistiques apparaissent sans aucun lien causal réel.
9. **a)** Définition à mémoriser : la variable cachée influence les deux variables observées et crée un lien apparent sans lien direct entre elles.
10. **b)** Piège de causalité inverse déguisé en feature adoption : l'engagement précède souvent l'usage de la fonctionnalité, pas l'inverse.
11. **c)** Variable cachée classique : le niveau de risque du magasin explique à la fois la présence du vigile et le nombre de vols détectés.
12. **d)** Biais de sélection : l'échantillon des répondants n'est pas représentatif, les clients mécontents étant sous-représentés voire déjà partis.
13. **a)** Le réflexe correct face à toute corrélation surprenante : chercher la variable cachée ou le biais avant de parler de cause, jamais l'inverse.
14. **b)** Piège du taux de base : avec une fraude très rare, même un modèle précis génère, en nombre absolu, plus de fausses alertes que de vraies.
15. **c)** Régression vers la moyenne : les cas les plus extrêmes ont statistiquement tendance à se rapprocher de la moyenne, indépendamment de toute intervention.
16. **d)** Piège de l'échantillon trop petit : 40 visiteurs sur 2 jours ne suffisent pas à distinguer un vrai effet du bruit statistique.
17. **a)** P-hacking par comparaisons multiples : tester 20 segments augmente mécaniquement la chance de tomber sur un faux positif à $p < 0,05$.
18. **b)** Piège du peeking : arrêter un test dès qu'un résultat favorable apparaît gonfle artificiellement le taux de faux positifs.
19. **c)** Effet de composition (mix shift) : un changement dans la part de chaque segment peut faire baisser la moyenne globale même si chaque segment progresse.
20. **d)** Le piège terrain le plus fréquent : la coïncidence temporelle n'est pas une preuve; il faut chercher les autres facteurs et, si possible, tester en A/B.

Fait main, en solo.

Si ce test t'a aidé, partage-le autour de toi : il peut débloquent un autre candidat. Et si tu veux que je traite un sujet précis, dis-le moi en commentaire : c'est là que je pioche mes prochains guides.

Dylan

