

8 datasets publics

8 cas d'entraînement



Chacun avec sa question de manager, son livrable attendu (SQL ou Power BI) et son piège fréquent.

Je vois trop de portfolios juniors bâtis sur des données inventées : propres, sans trou, sans vraie décision à prendre. Un recruteur repère ça en dix secondes. Ce guide te donne 8 terrains d'entraînement réels et vérifiables, pas 8 liens vagues, avec pour chacun la question qu'un manager poserait vraiment.

Bases classiques d'entraînement

Trois datasets notoires, pensés pour apprendre le geste avant d'affronter la donnée réelle : jointures propres, schéma clair, pas de bruit parasite.

1. Titanic, le classique pour apprendre le geste

Cas : Source : Kaggle, compétition **Titanic : Machine Learning from Disaster** (kaggle.com/c/titanic), fichier CSV téléchargeable gratuitement après création de compte.

Question manager : « Dis-moi qui avait le plus de chances de survivre sur ce bateau : la classe du billet, le sexe ou l'âge ? Et est-ce qu'on peut dire que la classe a causé la survie ? »

Livrable attendu : SQL, une requête **GROUP BY** sexe et classe avec taux de survie, reprise en Power BI dans un visuel matriciel sexe x classe.

Piège fréquent : une forte corrélation entre la 1^{re} classe et la survie ne prouve pas une causalité directe. Le vrai facteur est l'accès aux canots et le protocole d'évacuation ; la classe n'est qu'un marqueur socio-économique corrélé à cet accès.

2. Chinook, le terrain d'entraînement aux jointures qui trichent

Cas : Source : dépôt GitHub [lerocha/chinook-database](https://github.com/lerocha/chinook-database), base d'exemple prête à charger (SQLite, SQL Server, MySQL), qui simule un magasin de vente de musique en ligne.

Question manager : « Je veux le chiffre d'affaires par genre musical et par pays de facturation, pour vendredi. »

PIÈGE CLASSIQUE

Livrable attendu : SQL, une requête multi-jointures agrégée par genre et par pays.

```
SELECT g.Name AS genre, i.BillingCountry,
       SUM(ii.UnitPrice * ii.Quantity) AS revenue
FROM Invoice i
JOIN InvoiceLine ii ON ii.InvoiceId = i.InvoiceId
JOIN Track t ON t.TrackId = ii.TrackId
JOIN Genre g ON g.GenreId = t.GenreId
GROUP BY g.Name, i.BillingCountry;
```

Piège fréquent

Une jointure supplémentaire mal posée gonfle le chiffre sans erreur SQL visible.

Si tu rejoins la table Customer ou Employee sans clé propre, les lignes de facture se dupliquent et le chiffre d'affaires est gonflé silencieusement. Contrôle le nombre de lignes avant et après chaque jointure.

3. Northwind, le pont vers la modélisation Power BI

Cas : Source : dépôt GitHub [microsoft/sql-server-samples](https://github.com/microsoft/sql-server-samples), base d'exemple historique de Microsoft (clients, commandes, produits, catégories).

Question manager : « Pour le comité, je veux le chiffre d'affaires net de remise par catégorie de produit sur l'année, en rapport Power BI, pas en tableau brut. »

Livrable attendu : Power BI, modèle en étoile simplifié (faits [Order Details] relié à Products, Categories, Orders) avec une mesure DAX de CA net : $\text{UnitPrice} * \text{Quantity} * (1 - \text{Discount})$. Northwind n'a pas de colonne de coût, donc pas de marge calculable : si tu veux une marge, tu dois ajouter toi-même un coût d'achat.

Piège fréquent : Products.UnitPrice est un prix catalogue actuel, alors que le UnitPrice de [Order Details] est le prix réellement facturé au moment de la commande. Prendre le mauvais des deux, ou oublier Discount, fausse le chiffre d'affaires de chaque commande historique.

Données de terrain, format brut

Trois jeux de données réels, moins propres, plus proches de ce qui atterrit vraiment sur le bureau d'un analyste junior.

4. NYC TLC, le premier vrai volume brut

Cas : Source : nyc.gov/site/tlc, **TLC Trip Record Data**, fichiers mensuels publiés par la ville de New York depuis 2009 (taxis jaunes, verts, VTC).

Question manager : « Le service voirie veut caler les rotations : à quelles heures et quels jours la demande de taxis explose ? » **ÉLIMINATOIRE**

Livrable attendu : SQL, agrégation temporelle par jour de semaine et heure de prise en charge.

```
SELECT EXTRACT(DOW FROM tpep_pickup_datetime) AS jour,
       EXTRACT(HOUR FROM tpep_pickup_datetime) AS heure,
       COUNT(*) AS nb_courses
FROM yellow_tripdata
WHERE trip_distance BETWEEN 0.1 AND 100
   AND fare_amount > 0
GROUP BY jour, heure
ORDER BY jour, heure;
```

Pourquoi ce piège élimine

Le fichier brut contient des trajets à distance nulle, durée négative ou tarif à zéro (capteurs, tests internes). Sans filtre sur trip_distance et fare_amount, ces lignes aberrantes gonflent artificiellement des heures creuses et faussent la décision de planning.

5. Inside Airbnb, le dataset qui pousse vers la carte

Cas : Source : insideairbnb.com/get-the-data, extractions par ville (annonces, avis, calendrier), projet indépendant actif depuis 2015, mis à jour régulièrement.

Question manager : « Je veux voir où les prix Airbnb s'envolent dans la ville, quartier par quartier, en un coup d'œil. »

Livrable attendu : Power BI, visuel carte coloré par prix médian par quartier, avec segment sur le type de logement.

Piège fréquent : des annonces retirées du marché ou dupliquées par le scraping restent visibles dans l'export. Les confondre avec de vraies variations de prix fait remonter de faux quartiers « chers » qui n'ont en réalité presque plus d'offre active.

6. INSEE, l'ancrage institutionnel français

Cas : Source : insee.fr, données ouvertes (recensement de la population, base Sirene des entreprises), accès direct ou via l'API INSEE.

Question manager : « Le commerce recule-t-il vraiment dans notre département, ou est-ce juste qu'il y a moins d'entreprises créées cette année ? »

Livrable attendu : SQL pour extraire et nettoyer la base Sirene par secteur (code NAF) et département, puis tableau croisé Power BI de l'évolution par secteur et année.

Piège fréquent : confondre un taux (part du secteur en %) avec un effectif brut peut faire dire l'inverse de la réalité. Une rupture de série due à un changement de méthodologie (nouvelle nomenclature NAF, nouveau recensement) peut aussi ressembler à une vraie chute alors que c'est un artefact de mesure.

À retenir : ce que change un dataset brut

Un dataset pédagogique (Titanic, Chinook, Northwind) est nettoyé et cohérent : le problème est d'écrire la bonne requête. Un dataset de terrain (NYC TLC, Airbnb, INSEE) est publié tel quel : le problème devient de repérer ce qui est faux avant même d'agréger.

Dataset pédagogique

Schéma documenté, pas de doublon caché, résultat prévisible.

Objectif : maîtriser la syntaxe.

Dataset de terrain

Valeurs aberrantes, doublons de scraping, rupture de série possible.

Objectif : douter du chiffre avant de le publier.

Données institutionnelles et longitudinales

Deux sources officielles, pour t'entraîner à comparer dans le temps et entre pays sans te faire piéger par la méthodologie.

7. World Bank, l'entraînement à comparer sans tricher

Cas : Source : data.worldbank.org, **World Development Indicators**, des centaines d'indicateurs par pays et par année, export CSV ou API.

Question manager : « Le comité veut comparer le PIB par habitant de trois pays sur les dix dernières années, dans un visuel simple et comparatif. »

Livrable attendu : Power BI, graphique comparatif multi-pays avec sélecteur de pays et d'indicateur.

Piège fréquent : les indicateurs n'ont pas tous la même dernière année disponible selon le pays (données manquantes, retard de publication). Comparer 2023 pour un pays et 2019 pour un autre sans le signaler fausse silencieusement la comparaison.

8. Our World in Data COVID-19, le réflexe fenêtre glissante

Cas : Source : dépôt GitHub **owid/covid-19-data**, fichier CSV versionné couvrant cas, décès et vaccinations par pays et par jour. Le dépôt a été réorganisé depuis la période COVID : vérifie le nom exact du fichier et des colonnes le jour où tu le télécharges, la requête ci-dessous suit la mise en forme historique.

Question manager : « La courbe des nouveaux cas semble baisser ce week-end, on peut l'annoncer en comité lundi ? » **ÉLIMINATOIRE**

Livrable attendu : SQL fenêtré, moyenne mobile sur 7 jours pour lisser l'effet week-end, puis courbe Power BI avec la moyenne mobile superposée aux valeurs brutes.

```
SELECT date, location,  
       AVG(new_cases) OVER (  
         PARTITION BY location  
         ORDER BY date  
         ROWS BETWEEN 6 PRECEDING AND CURRENT ROW  
       ) AS moyenne_mobile_7j  
FROM covid_data  
WHERE location = 'France'  
ORDER BY date;
```

Pourquoi ce piège élimine

Une baisse en fin de semaine reflète le plus souvent un retard de déclaration, moins de tests remontés le week-end, pas une vraie amélioration. Sans lissage sur 7 jours, tu risques d'annoncer une tendance qui se rattrape mécaniquement le mardi suivant.

Le point commun des 8 pièges

Aucun des huit ne se résume à une formule oubliée. C'est toujours la même hypothèse implicite non vérifiée : la donnée dit ce qu'elle semble dire.

Avant de livrer un chiffre, pose la question qui protège : qu'est-ce qui pourrait rendre ce nombre faux sans qu'aucune erreur SQL ne s'affiche ? C'est cette question, pas la maîtrise d'un outil, qui distingue un portfolio crédible d'un exercice recopié.

Fait main, en solo.

Si ce guide t'a aidé, partage-le autour de toi : il peut débloquent un autre candidat. Et si tu veux que je traite un sujet précis, dis-le moi en commentaire : c'est là que je pioche mes prochains guides.

Dylan

