

30 questions d'entretien

Data Analyst

Avec, pour chaque question, la réponse attendue

Un recruteur ne note pas une réponse parfaite récitée. Il écoute ton raisonnement : est-ce que tu vois le piège, est-ce que tu sais pourquoi, est-ce que tu traduis en impact métier. Ce guide te donne ce raisonnement, terrain par terrain. Pour chaque question : le piège où tombe un junior, et la **réponse attendue** par le recruteur, sur les 4 terrains qui reviennent en entretien Data Analyst : SQL, DAX et modélisation, dataviz, et la mise en situation. Les questions marquées d'un ★ sont celles qui éliminent le plus souvent.

■ ■ ■ SQL : jointures, agrégats, fenêtres

1. Différence entre `INNER JOIN` et `LEFT JOIN` ?

Le piège : Répondre « l'un garde tout, l'autre filtre » sans dire ce qui décide.

Réponse attendue : L'`INNER JOIN` ne garde que les lignes qui ont une correspondance des deux côtés. Le `LEFT JOIN` garde toutes les lignes de gauche et met `NULL` à droite quand il n'y a pas de correspondance. Montre que tu sais quand le choisir : tu prends un `LEFT JOIN` quand l'absence de correspondance est une information (un client sans commande).

2. Une condition dans le `ON` ou dans le `WHERE` d'un `LEFT JOIN`, c'est pareil ? ★

Le piège : Dire que ça revient au même.

Réponse attendue : Non. Une condition sur la table de droite placée dans le `WHERE` élimine les lignes à `NULL`, donc ton `LEFT JOIN` se comporte comme un `INNER JOIN`. Dans le `ON`, elle filtre la table de droite avant la jointure et garde toutes les lignes de gauche. Sache le dire, c'est un classique qui élimine.

3. Un `JOIN` peut-il faire augmenter le nombre de lignes ?

Le piège : Penser qu'une jointure ne fait jamais grossir le résultat.

Réponse attendue : Oui, si la clé de jointure a des doublons côté droit. Un identifiant présent 3 fois triple la ligne de gauche. C'est la cause numéro un des chiffres d'affaires gonflés dans un dashboard : tu vérifies l'unicité de la clé avant de joindre, puis tu compares le nombre de lignes avant et après.

4. Différence entre `WHERE` et `HAVING` ?

Réponse attendue : Le `WHERE` filtre les lignes avant le regroupement, le `HAVING` filtre les groupes après l'agrégation. Donc un filtre sur une valeur agrégée (`SUM`, `COUNT`) va dans le `HAVING` ; un filtre sur une colonne brute va dans le `WHERE`, plus efficace car il réduit le volume en amont.

5. Différence entre `COUNT(*)`, `COUNT(col)` et `COUNT(DISTINCT col)` ?

Réponse attendue :

- `COUNT(*)` : toutes les lignes, `NULL` compris.
- `COUNT(col)` : lignes où la colonne n'est pas `NULL`.
- `COUNT(DISTINCT col)` : valeurs uniques non-`NULL`.

Précise que te tromper de variante fausse un KPI sans aucun message d'erreur : c'est ce qui rend la question piègeuse.

6. Peux-tu filtrer dans le `WHERE` sur un alias défini dans le `SELECT` ?

Le piège : Répondre oui par habitude.

Réponse attendue : Non. Dans l'ordre logique, le `WHERE` est évalué avant le `SELECT` : l'alias n'existe pas encore. Tu répètes l'expression, ou tu passes par une CTE. L'alias est en revanche utilisable dans le `ORDER BY`. Cette réponse montre que tu connais l'ordre d'exécution, pas juste la syntaxe.

7. À quoi sert `GROUP BY` et que peut-on mettre dans le `SELECT` avec ?

Le piège : Mettre une colonne non agrégée et non groupée dans le `SELECT`.

Réponse attendue : Chaque colonne du `SELECT` doit être soit dans le `GROUP BY`, soit dans une fonction d'agrégation. Sinon la valeur affichée est indéterminée : PostgreSQL et SQL Server refusent, et MySQL aussi par défaut depuis la 5.7 (mode `ONLY_FULL_GROUP_BY`) ; ce mode désactivé, MySQL renvoie une ligne arbitraire, ce qui produit des résultats faux silencieux.

8. Différence entre `ROW_NUMBER()`, `RANK()` et `DENSE_RANK()` ?

Réponse attendue : Sur des ex-aequo (10, 10, 20) :

- `ROW_NUMBER` : 1, 2, 3 (numérotation unique, arbitraire sur les ex-aequo).
- `RANK` : 1, 1, 3 (saute le rang 2).
- `DENSE_RANK` : 1, 1, 2 (pas de trou).

Donne l'usage : dédoublonner avec `ROW_NUMBER`, classer un podium avec `RANK`.

9. À quoi sert `PARTITION BY` dans une fonction de fenêtrage? ★

Le piège : Le confondre avec un GROUP BY.

Réponse attendue : Le PARTITION BY définit le périmètre de calcul de la fenêtre sans agréger : tu gardes toutes les lignes de détail tout en calculant une valeur par groupe (un rang par département, un cumul par client). Le GROUP BY, lui, réduit à une ligne par groupe.

```
SELECT client_id, date_cmd,  
       ROW_NUMBER() OVER (  
         PARTITION BY client_id  
         ORDER BY date_cmd  
       ) AS rang  
FROM commandes;
```

■ ■ ■ DAX & modélisation : contexte, étoile, mesure

10. Différence entre contexte de ligne et contexte de filtre? ★

Le piège : Les confondre, ou dire qu'une mesure « parcourt les lignes ».

Réponse attendue : Ce sont deux mécanismes séparés. Le contexte de ligne est le pointeur « ligne courante » : il existe dans une colonne calculée et dans un itérateur (SUMX, FILTER). Le contexte de filtre est l'ensemble des filtres posés par les visuels, segments et relations. Une mesure s'évalue une seule fois dans le contexte de filtre de sa cellule, elle n'itère pas les lignes.

11. À quoi sert CALCULATE?

Le piège : Dire « ça calcule » sans parler du contexte de filtre.

Réponse attendue : CALCULATE est la fonction qui modifie le contexte de filtre dans lequel s'évalue son expression. Trois comportements : elle remplace le filtre existant sur une colonne déjà filtrée, elle ajoute un filtre sur une colonne qui ne l'était pas, et elle peut retirer des filtres avec ALL. KEEPFILTERS rend le remplacement additif.

12. Quand faire une mesure plutôt qu'une colonne calculée? ★

Le piège : Tout mettre en colonnes calculées.

Réponse attendue : La colonne calculée est évaluée à l'actualisation, ligne par ligne, et stockée dans le modèle (elle pèse en mémoire). La mesure est évaluée à la requête, dans le contexte de filtre courant, et n'est pas stockée. Règle : un attribut par ligne réutilisé en axe, segment ou relation, c'est une colonne ; une agrégation qui doit réagir aux filtres, c'est une mesure. Une agrégation en colonne se fige à l'actualisation et ne bouge plus quand l'utilisateur filtre.

13. Que fait SUMX de différent par rapport à SUM?

Réponse attendue : SUM agrège une seule colonne. SUMX est un itérateur : il parcourt une table ligne par ligne, crée un contexte de ligne, évalue une expression sur chaque ligne, puis somme. C'est ce qui te permet de calculer une expression par ligne avant d'additionner.

```
Chiffre =  
SUMX ( Ventes, Ventes[PU] * Ventes[Qte] )
```

14. C'est quoi la « transition de contexte » ?

Réponse attendue : C'est ce qui se passe quand CALCULATE s'exécute dans un contexte de ligne : il transforme la ligne courante en filtres de colonnes équivalents, puis évalue son expression. C'est pour ça qu'appeler une mesure dans un SUMX fonctionne : la mesure est implicitement entourée d'un CALCULATE, qui déclenche la transition et fait que la mesure n'agrège que les données de cette ligne.

15. Dans quel sens une relation filtre-t-elle dans un modèle en étoile ?

Le piège : Croire que le filtre circule dans les deux sens par défaut.

Réponse attendue : Par défaut le filtre va du côté « un » (la dimension) vers le côté « plusieurs » (la table de faits), en sens unique. Choisir un produit dans un segment filtre les ventes, pas l'inverse. Le filtrage bidirectionnel existe mais s'utilise avec prudence, il peut fausser des calculs.

16. Pourquoi privilégier un modèle en étoile plutôt qu'en flocon dans Power BI ? ★

Le piège : Normaliser les dimensions comme dans une base transactionnelle.

Réponse attendue : Le moteur VertiPaq compresse très bien les colonnes de dimension à faible cardinalité. L'étoile, avec des dimensions à plat, joue sur cette force. Le flocon allonge les chaînes de relations que le moteur doit traverser à la requête et ajoute des tables sans gagner en compression. DAX est aussi pensé pour une topologie en étoile : un saut unique dimension vers faits. On tolère un flocon seulement si aplatir une très grosse dimension coûterait plus cher en stockage.

17. Différence entre relation active et relation inactive ?

Réponse attendue : Entre deux tables, une seule relation peut être active à la fois : c'est elle qui propage les filtres automatiquement. Les autres sont inactives, tracées en pointillés. Cas typique : une table de faits avec date de commande et date de livraison, toutes deux liées au calendrier. Tu actives celle dont tu as besoin dans une mesure avec USERELATIONSHIP à l'intérieur d'un CALCULATE.

■ ■ ■ Dataviz : le graphique qui décide

18. Quelle est selon toi la différence entre un graphique qui décoore et un graphique qui décide ?

Le piège : Répondre par l'esthétique (« des couleurs cohérentes »).

Réponse attendue : Un graphique qui décide répond à une question précise et déclenche une action : on doit pouvoir nommer la décision qu'il sert. Un graphique qui décoore est joli mais ne change aucun arbitrage. Le critère, c'est « que fait le lecteur différemment après l'avoir vu ». C'est exactement ce qu'un manager veut t'entendre dire.

19. Camembert (pie chart) ou barres pour comparer des catégories ?

Le piège : Défendre le camembert parce qu'il est « parlant ».

Réponse attendue : Des barres, presque toujours. L'œil compare mal des angles, surtout au-delà de 3 ou 4 parts ou quand les valeurs sont proches. Le camembert reste acceptable pour une part dominante évidente sur 2-3 segments. La règle : comparer = position le long d'un axe, donc des barres.

20. Quel visuel pour montrer une évolution dans le temps ?

Réponse attendue : Une courbe (line chart) quand les points sont nombreux et continus : elle montre la tendance. Des barres quand les périodes sont peu nombreuses et discrètes, ou quand chaque période est comparée individuellement. Le réflexe à montrer : tu choisis selon la question, pas par habitude.

21. Faut-il toujours faire commencer l'axe des valeurs à zéro ? ★

Le piège : Répondre « oui » ou « non » sans distinguer.

Réponse attendue : Ça dépend du visuel. Pour des barres, oui : la longueur encode la valeur, un axe tronqué exagère visuellement les écarts et trompe le lecteur. Pour une courbe qui montre une variation fine, un axe non nul peut être justifié, à condition de le rendre lisible. Montrer cette nuance prouve que tu penses à l'honnêteté de la lecture.

22. Comment choisis-tu les couleurs d'un dashboard ?

Le piège : Multiplier les couleurs « pour que ce soit vivant ».

Réponse attendue : La couleur porte du sens, elle n'est pas décorative : une couleur d'accent pour ce qui compte, du gris pour le contexte. Tu gardes une palette sobre, cohérente d'un visuel à l'autre, et tu vérifies le contraste pour les daltoniens (éviter le rouge/vert seul). Trop de couleurs tue la hiérarchie de lecture.

23. Un dirigeant a 10 secondes : que mets-tu en haut du dashboard ?

Réponse attendue : Les 3-4 chiffres qui répondent à sa question, en grand, avec leur évolution (vs objectif ou vs période précédente). Le détail vient dessous, dans l'ordre de lecture. La logique à exprimer : du général au particulier, une seule idée par zone, et l'essentiel lisible sans cliquer ni scroller.

■ ■ ■ Mise en situation : le terrain

24. Tu as envoyé un reporting, et tu réalises qu'un chiffre est faux. Que fais-tu? ★

Le piège : Attendre que personne ne remarque, ou corriger en silence.

Réponse attendue : Tu préviens vite et toi-même, avant que quelqu'un d'autre le découvre. Tu dis ce qui est faux, l'ampleur de l'impact, et la version corrigée avec la cause. Le recruteur teste ta fiabilité, pas ta perfection : un junior qui signale une erreur rassure plus qu'un junior qui n'en fait jamais.

25. Un responsable métier conteste ton chiffre et affirme que le sien est le bon. Comment réagis-tu?

Le piège : Avoir raison contre lui, ou plier sans vérifier.

Réponse attendue : Tu cherches d'où vient l'écart, pas qui a raison : périmètre, période, définition de la métrique, filtres. Le plus souvent les deux chiffres sont justes mais ne mesurent pas la même chose. Tu alignes les définitions avec lui, puis tu tranches. Posture collaborative, pas défensive.

26. On te confie trois demandes urgentes en même temps. Comment priorises-tu?

Réponse attendue : Tu ne traites pas dans l'ordre d'arrivée. Tu évalues l'impact et l'échéance réelle de chaque demande, tu poses la question à qui pilote en cas d'ambiguïté, et tu communique ce que tu fais d'abord et quand le reste arrive. Montrer que tu sais dire « voici l'ordre que je propose, valides-tu ? » vaut mieux que de tout promettre.

27. Comment expliques-tu un résultat technique à quelqu'un qui n'est pas data?

Le piège : Détailler la méthode et le jargon.

Réponse attendue : Tu pars de sa question et de la décision qu'il doit prendre, pas de ta requête. Tu donnes le résultat et son sens d'abord, puis le « comment » seulement s'il le demande. Une analogie concrète vaut mieux qu'une formule. Cette capacité à traduire est ce qui distingue un analyste utile.

28. On te demande une analyse mais la consigne est floue. Que fais-tu?

Le piège : Foncer et livrer ce que tu as compris.

Réponse attendue : Tu reformules le besoin et la décision visée avant de produire : « si je comprends bien, tu veux savoir X pour décider Y ». Tu cadres le périmètre, la période et la définition des métriques. Cinq minutes de cadrage évitent une demi-journée de travail à côté du sujet. Le recruteur cherche ce réflexe-là.

29. Ton analyse donne un résultat surprenant, contre-intuitif. Que fais-tu avant de l'annoncer ?

Le piège : L'annoncer tel quel parce que « les données ne mentent pas ».

Réponse attendue : Tu doutes d'abord de ta donnée : doublons de jointure, filtre oublié, valeurs nulles, période mal bornée. Un résultat étonnant est plus souvent un bug qu'une découverte. Tu vérifies, tu recoupes sur une autre source, et seulement après tu présentes, en expliquant pourquoi tu as confiance.

30. Comment t'assures-tu qu'une analyse est réutilisable et pas un travail jetable ?

Réponse attendue : Tu documentes les sources, les définitions de métriques et les hypothèses ; tu nommes clairement requêtes et fichiers ; tu rends le calcul rejouable plutôt que bricolé à la main dans un coin. Penser « quelqu'un d'autre, ou moi dans six mois, doit pouvoir relancer ça » est la marque d'un analyste fiable.

■■■ **Le réflexe à retenir**

Le recruteur ne teste pas ta syntaxe, il teste ton raisonnement. Pour chaque question, montre que tu vois le piège, que tu sais pourquoi, et que tu traduis en impact métier.

→ **Garde ce guide sous la main avant ton prochain entretien : ces 30 questions reviennent.**